

Psychiatria obliczeniowa

Streszczenie

Psychiatria obliczeniowa to dziedzina na styku psychiatrii, neuronauki i nauk obliczeniowych, której celem jest formalny opis objawów, procesów poznawczych i zaburzonych mechanizmów mózg–zachowanie za pomocą modeli matematycznych, statystycznych i algorytmicznych. W praktyce łączy ona dwa nurty: **mechanistyczny** - oparty na modelach generatywnych, inferencji bayesowskiej, uczeniu ze wzmocnieniem i dynamice układów - oraz **predykcyjny** - oparty na uczeniu maszynowym i analizie danych wielomodalnych. Jej ambicją nie jest tylko „automatyzacja diagnozy”, lecz zbudowanie lepiej skalibrowanych, bardziej biologicznie i poznawczo interpretowalnych fenotypów klinicznych oraz narzędzi prognostycznych i terapeutycznych. [1]

Najbardziej przekonujące wyniki empiryczne z ostatnich lat dotyczą obecnie czterech obszarów: rozkładania objawów na ukryte procesy obliczeniowe, przewidywania ryzyka przejścia do psychozy w ujęciu multimodalnym, przewidywania odpowiedzi na leczenie przeciwdepresyjne oraz ciągłego monitorowania ryzyka i nasilenia objawów na podstawie danych cyfrowych. Przykładowo, multimodalny sekwencyjny workflow w młodych osobach z wysokim ryzykiem psychozy lub świeżo rozpoznaną depresją osiągnął zbalansowaną trafność 85,9%, a model predykcji odpowiedzi na sertralinę oparty na MRI i danych klinicznych osiągnął AUROC 0,73. Jednocześnie duże badania normatywnego modelowania w psychozie wysokiego ryzyka pokazały, że makroskalowe markery morfometrii mają ograniczoną wartość diagnostyczną, a część zadań poznawczych używanych w badaniach klinicznych okazuje się psychometrycznie zbyt słaba dla użytku translacyjnego. [2]

Stan dziedziny jest więc obiecujący, ale nierówny. Najsilniejsze rezultaty pojawiają się wtedy, gdy łączy się **modele formalne, pomiar powtarzany w czasie, multimodalne dane biologiczne i behawioralne oraz zewnętrzną walidację**. Największymi barierami pozostają: małe próby, zawyżanie wyników w badaniach jednośrodkowych, brak kalibracji modeli, niska rzetelność zadań, heterogeniczność zaburzeń oraz problemy etyczne i regulacyjne dotyczące prywatności, zgody, stronniczości algorytmicznej i nadzoru nad AI medyczną. W Unii Europejskiej ten ostatni obszar jest już bezpośrednio dotykany przez GDPR, AI Act i Europejską Przestrzeń Danych dotyczących Zdrowia. [3]

Definicja i zakres

Najkrócej, psychiatria obliczeniowa formalizuje zaburzenia psychiczne jako zaburzenia **wnioskowania, uczenia, wyceny, kontroli i dynamiki sieciowej**, a następnie testuje te formalizacje na danych behawioralnych, neuroobrazowych, elektrofizjologicznych, genetycznych i cyfrowych. Klasyczna definicja Adamsa, Huysa i Roisera ujmuje ją jako próbę opisanie relacji między neurobiologią mózgu, środowiskiem i objawami psychicznymi w kategoriach obliczeniowych; późniejsze ujęcie Huysa, Mai i Franka podkreślało funkcję „mostu” łączącego odkrycia neuronauk z praktyką kliniczną; nowsze przeglądy opisują pole jako przecięcie psychiatrii, neuronauki i informatyki używające modeli matematycznych i symulacji do wyjaśniania złożoności zaburzeń psychicznych. [1]

To rozróżnienie jest istotne, bo psychiatria obliczeniowa **nie jest synonimem AI w psychiatrii**. Uczenie maszynowe stanowi tylko jeden z jej komponentów. Równie ważne są modele generatywne, które próbują oszacować ukryte parametry poznawcze i neuronalne, takie jak szybkość uczenia, wrażliwość na wynik, precyzja przekonań, oczekiwana zmienność środowiska czy siła błędu predykcji. Właśnie te parametry mają potencjalnie największą wartość mechanistyczną: mogą łączyć objaw z obwodem neuronalnym i interwencją terapeutyczną. [4]


Współczesne teksty programowe coraz częściej traktują tę dziedzinę jako pomost między **translacją** a **psychiatrią precyzyjną**: z jednej strony ma ona wyprowadzać testowalne mechanizmy z neuronauki i psychologii obliczeniowej, z drugiej - budować narzędzia wspomagające diagnozę, rokowanie i dobór leczenia u konkretnego pacjenta. W tym sensie psychiatria obliczeniowa ma charakter zarówno epistemiczny, jak i infrastrukturalny: tworzy nowe teorie, ale też nowe sposoby organizowania danych, walidacji i decyzji klinicznych. [5]

W polskim obiegu instytucjonalnym definicja ta pojawia się już explicite. Oficjalny opis Zespołu Psychiatrii Obliczeniowej w Centrum Sztucznej Inteligencji UAM określa tę dziedzinę jako obszar wykorzystujący analizę danych i modelowanie matematyczne do obiektywizacji opisu stanu psychicznego, lepszego rozumienia etiopatogenezy zaburzeń i optymalizacji strategii leczenia. To ważny sygnał, że także w Polsce pole zaczyna się instytucjonalizować, choć dominująca literatura pierwotna pozostaje nadal anglojęzyczna. [6]

Rozwój historyczny i kamienie milowe

Genealogia psychiatrii obliczeniowej sięga znacznie dalej niż sama nazwa pola. Jednym z fundamentów był model Rescorli i Wagnera z 1972 roku, który sformalizował uczenie jako aktualizację oczekiwań napędzaną błędem predykcji. Drugim była praca Schultza, Dayana i Montague'a z 1997 roku, łącząca sygnały dopaminergiczne z błędem predykcji nagrody. Trzecim ważnym krokiem była zasada swobodnej energii i rozwój active inference, które rozszerzyły pogląd na mózg jako system wnioskujący i działający w celu minimalizacji niepewności i „zaskoczenia”. Wczesne lata 2010. przyniosły konsolidację samego pola jako odrębnego programu badawczego, a dekada 2020. - przejście do infrastruktur wielkoskalowych, normatywnych i cyfrowych. [7]

Wybrane kamienie milowe psychiatrii obliczeniowej




Oś czasu syntetyzuje klasyczne formalizacje uczenia i inferencji z późniejszym rozwojem instytucji oraz otwartych zasobów. Szczególnie istotne było utworzenie w 2012 roku Translational Neuromodeling Unit w ETH/UZH, której misją od początku było rozwijanie modeli pozwalających wnioskować o indywidualnych zaburzeniach fizjologii i przetwarzania informacji na podstawie neuroobrazowania, elektrofizjologii i zachowania. W latach 2020. równolegle dojrzały zasoby otwarte: OpenNeuro jako archiwum danych BIDS, UK Biobank z 500 tys. wolontariuszy i ukończonym w 2025 roku programem 100 tys. skanów obrazowych oraz duże kohorty rozwojowe i konsorcja typu ABCD, HCP i ENIGMA. [8]

W praktyce historyczny rozwój pola można ująć jako przejście od **prostych modeli uczenia** do **modeli wielopoziomowych**, a następnie do **hybryd mechanistyczno-predykcyjnych**. Współczesne badania nie pytają już jedynie, czy pacjent „różni się” od kontroli, lecz które parametry wnioskowania, uczenia i regulacji

są zaburzone, na ile są stabilne, czy można je zmienić leczeniem oraz czy przewidują przebieg choroby u konkretnej osoby. [9]

Ramy teoretyczne, metody i dane

W praktyce badawczej psychiatria obliczeniowa przebiega zwykle według tego samego schematu: z danych wielomodalnych estymuje się albo **ukryte parametry mechanistyczne**, albo **wynik predykcyjny**, po czym ocenia się ich trafność kliniczną, kalibrację i generalizowalność. W dojrzałych zastosowaniach oba podejścia bywają łączone, np. gdy parametry modelu poznawczego stają się wejściem do modelu prognostycznego. [10]



Rodzina metod	Formalizm i typowe parametry	Najczęstsze dane wejściowe	Główna wartość	Główne ograniczenia	Źródła
Modele bayesowskie i predictive processing	priory, likelihood, precyzja, niepewność, zmienność środowiska, ukryte stany	zadania poznawcze, fMRI, EEG, pupilometria	pozwalają opisać zaburzenia jako błędy inferencji i ważenia dowodu; szczególnie użyteczne w psychozie, interocepcji i niepewności	identyfikowalność parametrów zależy od jakości zadania; interpretacja bywa wrażliwa na założenia modelu	[11]
Uczenie ze wzmocnieniem	value update, learning rate, outcome sensitivity, perseveration, błędy predykcji	zadania probabilistyczne, reversal learning, bandity, task-fMRI	dobrze łączy zachowanie z sygnałami dopaminergicznymi i obwodami prążkowia; szczególnie przydatne w depresji, OCD, uzależnieniach	wyniki silnie zależą od konstrukcji zadania i rzetelności wykonania; częste problemy psychometryczne	[12]
Modele generatywne hierarchiczne	HGF, DCM, modele stan–obserwacja, precision-weighted learning	zachowanie, EEG/MEG, fMRI, dane czasowe	estymują ukryte poziomy dynamiki poznawczej i obwodowej; nadają się do symptom-specific phenotyping	wyższa złożoność, większe wymagania obliczeniowe i metodologiczne	[13]
Dynamika układów i control systems	przestrzeń stanów, atraktory, stabilność, sterowanie, zależności czasowe	EMA, cyfrowe fenotypowanie, ciągły zapis EEG, zachowanie naturalistyczne	najlepiej opisują niestacjonarne, ciągle procesy objawowe i mogą wspierać closed-loop interventions	trudne modele, duże wymagania co do gęstości danych i jakości ciągłego pomiaru	[14]
Modele sieciowe	węzły-symptomy lub regiony, krawędzie częściowych zależności, mosty między domenami	skale objawowe, EMA, genetyka, connectomics	dobrze ujmują współwystępowanie, centralność objawów i sieciową heterogeniczność	zależności nie są automatycznie przyczynowe; sieci bywają niestabilne przy małych próbach	[15]
Uczenie maszynowe	klasyfikacja, regresja, embedding, stacking, deep learning	dane kliniczne, MRI, EEG, PRS, EHR, smartfon	największa siła predykcyjna i łatwość integracji multimodalnej	wysokie ryzyko overfittingu, słaba kalibracja, niska transparentność i problemy z transportowalnością	[16]
Normative modeling	odchylenie od normy względem dużej referencji populacyjnej	głównie neuroobrazowanie, coraz częściej także dane funkcjonalne i molekularne	pozwała opisać heterogeniczność na poziomie jednostki zamiast średnich grupowych	wymaga bardzo dużych, dobrze scharakteryzowanych populacji referencyjnych i harmonizacji między ośrodkami	[17]

Modalność	Co mierzy	Atut metodologiczny	Typowe ograniczenie	Przykłady zastosowań	Źródła
Zadania	wybór, uczenie,	niska cena, bezpośrednie	silna zależność od jakości	reward/loss learning,	[18]

Modalność	Co mierzy	Atut metodologiczny	Typowe ograniczenie	Przykłady zastosowań	Źródła
behawioralne i EMA	niepewność, zmienność objawów w czasie	sprzężenie z teorią	zadania i zaangażowania uczestnika	Go/NoGo, reversal, social inference	
fMRI, sMRI, dMRI	aktywacja, łączność, morfometria, mikrostruktura	bogate mapowanie obwodów i lokalizacji	wysoki koszt, site effects, umiarkowana transportowalność	predykcja odpowiedzi, risk stratification, normative modeling	[19]
EEG i MEG	dynamika czasowa, oscylacje, connectivity, komponenty wywołane	wysoka rozdzielczość czasowa, niższy koszt, potencjał skalowania	wrażliwość na artefakty i konieczność standaryzacji cech	biomarkery odpowiedzi na rTMS i leczenie przeciwdepresyjne	[20]
Cyfrowe fenotypowanie	aktywność, lokalizacja, wzorce używania telefonu, sen, EMA	pomiar ekologiczny i ciągły, możliwość monitoringu	prywatność, missingness, selekcja użytkowników, bias urządzeń	monitoring ryzyka, wczesne wykrywanie, JITA	[21]
Genetyka i PRS	poligeniczne obciążenie i podatność molekularna	dobrze skaluje się w dużych kohortach i wspiera analizę transdiagnostyczną	zwykle słaba moc predykcyjna jako pojedyncza modalność	uzupełnienie modeli multimodalnych, analiza sieci symptomów	[22]

Warto podkreślić, że w zastosowaniach klinicznych najbardziej obiecujące są dziś **kombinacje** metod: parametry poznawcze zadań, dane obrazowe, cechy kliniczne, wyniki kwestionariuszy i sygnały smartfonowe. Zwiększa to zarówno trafność predykcji, jak i interpretowalność mechanistyczną - pod warunkiem rzetelnej walidacji zewnętrznej. [23]

Pytania kliniczne i zasoby

Najważniejsze pytania badawcze w psychiatrii obliczeniowej można sprowadzić do pięciu klas. Po pierwsze, **mechanistyczne rozbicie objawów**: które składniki anhedonii, negatywnego afektu, kompulsji, urojeń czy halucynacji odpowiadają zmianom w uczeniu, wycenie, ważeniu dowodu lub dynamice sieci? Po drugie, **diagnoza i różnicowanie**: czy modele mogą wspomóc klasyfikację, ale bez redukcji psychiatrii do prostego rozpoznawania wzorców? Po trzecie, **rokowanie**: kto przejdzie do psychozy, kto się pogorszy, kto utrzyma remisję? Po czwarte, **predykcja odpowiedzi na leczenie**: który pacjent skorzysta z SSRI, CBT, rTMS lub innej interwencji? Po piąte, **monitoring w świecie rzeczywistym**: jak wykrywać zmianę stanu zanim stanie się klinicznie jawna. [24]

Wiodące ośrodki badawcze pokazują, jak szerokie jest dziś pole. TNU w Zurychu deklaruje rozwój modeli wnioskujących o indywidualnych zaburzeniach fizjologii i przetwarzania informacji z neuroobrazowania, elektrofizjologii i zachowania; Max Planck UCL Centre koncentruje się na przyczynach zaburzeń psychicznych oraz różnic indywidualnych w relacjach mózg–zachowanie; Applied Computational Psychiatry Lab w UCL stawia wyraźnie na narzędzia z realnym potencjałem klinicznym; 4C Lab w Wisconsin akcentuje modelowanie przyczynowe i mechanistyczne zaburzeń psychicznych na poziomie jednostki i grupy; Yale Computational Psychiatry Unit rozwija ekologicznie trafne ramy i modele dla psychiatrii, a Center for Computational Psychiatry w Mount Sinai deklaruje wykorzystanie ilościowych i obiektywnych narzędzi do poprawy diagnozy i leczenia. W Polsce najbardziej bezpośrednio nazwaną inicjatywą pozostaje Zespół Psychiatrii Obliczeniowej w CSI UAM. Dedykowanym miejscem publikacji jest też czasopismo *Computational Psychiatry*. [25]

Zasób	Skala i modalności	Dlaczego jest ważny dla psychiatrii obliczeniowej	Uwagi praktyczne	Źródła
OpenNeuro	1 741 publicznych datasetów, 78 785 uczestników; MRI, PET, MEG, EEG, iEEG; standard BIDS	wspiera otwartość, reanalizy, benchmarki i replikację metod	dane otwarte, ale heterogeniczne; jakość zależy od datasetu	[26]
UK Biobank	500 000 wolontariuszy; genomika, EHR, lifestyle, obrazowanie; program obrazowy ukończył 100 000 skanów w 2025 r.	kluczowy zasób do modeli populacyjnych, normatywnych i transdiagnostycznych	dostęp dla uprawnionych badaczy; kohorta nie jest klinicznie reprezentatywna dla całej populacji	[27]
ABCD Study	11 880 dzieci w wieku 9–10 lat	najlepszy zasób do rozwojowej	kohorta dziecięco- młodzieżowa, dane	[28]

Zasób	Skala i modalności	Dlaczego jest ważny dla psychiatrii obliczeniowej	Uwagi praktyczne	Źródła
	na starcie; pomiary rozwojowe, MRI, zdrowie psychiczne, środowisko	psychiatrii obliczeniowej i trajektorii ryzyka	w NDA	
Human Connectome Project	CCF obsługuje 20 badań; release S1200 obejmuje 1 206 zdrowych młodych dorosłych z multimodalnym MRI, częściowo 7T i MEG	referencyjny standard jakości dla connectomics i analizy obwodów	węższy zakres kliniczny, ale bardzo wysoka jakość danych	[29]
NIMH Data Archive	dane z setek projektów, wielu domen naukowych	infrastruktura do harmonizacji i ponownego użycia danych psychiatrycznych i rozwojowych	dostęp warstwowy; wymaga pracy nad harmonizacją zmiennych	[30]
ENIGMA	międzynarodowe konsorcjum imaging-genetics z grupami roboczymi dla schizofrenii, depresji, ADHD, OCD i innych	umożliwia megaanalizy, harmonizację i testowanie efektów małych wielkości	często pracuje na podsumowanych lub federowanych danych, nie zawsze na surowych danych jednostkowych	[31]
PRONIA	multimodalna kohorta wczesnej psychozy i depresji z 7 ośrodków w 5 krajach Europy	wzorcowy zasób do prognozyki psychotycznej i budowy workflow klinicznych	specjalistyczna kohorta, nie w pełni populacyjna	[32]
EMBARC	randomizowane badanie biomarkerów odpowiedzi przeciwdepresyjnej; 296 chorych w projekcie bazowym	jeden z najważniejszych zasobów do predykcji odpowiedzi na leczenie i biomarkerów MDD	dostęp i analizy wtórne wymagają rygoru metodologicznego	[33]
CentileBrain	portal z pretrenowanymi modelami normatywnymi dla morfometrii mózgu	przyspiesza przejście od średnich grupowych do odchyłeń jednostkowych	użyteczność zależy od zgodności danych wejściowych z referencją	[34]
CPSYMAP	mapa piśmiennictwa wzdłuż wymiarów neuronaukowych, psychiatrycznych i obliczeniowych	użyteczna do nawigacji po szybko rosnącym polu i identyfikacji nisz badawczych	to zasób metanaukowy, nie baza danych pacjentów	[35]

Reprezentatywne badania empiryczne

Poniżej zestawiono reprezentatywne badania z lat 2021–2026. Dobór jest celowo mieszany: obejmuje wyniki pozytywne, ale także badania „negatywne”, które dobrze pokazują realne granice współczesnej dziedziny.

Badanie	Próba	Modalności i metoda	Kluczowe wyniki ilościowe	Wniosek kliniczno-mechanistyczny	Źródła
Brown i wsp., 2021, <i>JAMA Psychiatry</i>	101 dorosłych na starcie; 69 z depresją i 32 bez; follow-up 48, w tym 28 po CBT	probabilistyczne zadania reward/loss podczas fMRI + model RL	anhedonia wiązała się z parametrami reward learning, a negatywny afekt z loss learning; poprawa po CBT korelowała z normalizacją parametrów: reward learning rate $\beta=0,15$ (90% CrI 0,001–0,41), loss outcome shift $\beta=0,42$ (90% CrI 0,09–0,77)	objawy depresyjne można rozbić na różne mechanizmy obliczeniowe, a zmiany tych mechanizmów mogą śledzić efekty terapii	[36]
Koutsouleris i wsp., 2021, <i>JAMA Psychiatry</i>	334 pacjentów i 334 kontrole; 26 przejść do psychozy; walidacja zewnętrzna: 45 transition + 600 nontransition	sekwencyjny multimodalny ML: klinika/neurokognicja + rating klinicysty + PRS + sMRI	BAC 85,9%, czułość 84,6%, swoistość 87,3%; częstość wyników fałszywie ujemnych spadła z 38,5% do 15,4%	multimodalny, etapowy workflow może realnie wspierać stratyfikację ryzyka psychozy	[37]
Tavares i wsp., 2023, <i>Frontiers in Psychiatry</i>	246 osób z ARMS, z czego 60 później przeszło do psychozy	sMRI + genotypowanie genome-wide + ryzyka środowiskowe; SVM, logistic regression, elastic net	żadna modalność sama nie przewidywała przejścia statystycznie lepiej niż przypadek; multimodalnego modelu nie trenowano	ważny wynik temperujący nadmierny optymizm wobec sMRI i genetyki w małych/średnich próbach prognostycznych	[38]
Poirot i wsp., 2024, <i>American Journal of Psychiatry</i>	229 pacjentów z MDD z randomizowanego EMBARC	multimodalne MRI + dane kliniczne na starcie i po 1 tygodniu; ML	dla odpowiedzi na sertralinę: internal CV bAcc=68% (SD 10), AUROC=0,73 (SD 0,03); walidacje zewnętrzne: bAcc 62%/65%, AUROC 0,66/0,68; modele multimodalne >	predykcja odpowiedzi na konkretny lek jest możliwa, ale nadal umiarkowana i zależna od walidacji	[39]

Badanie	Próba	Modalności i metoda	Kluczowe wyniki ilościowe	Wniosek kliniczno-mechanistyczny	Źródła
Malamud i wsp., 2024, <i>Psychological Medicine</i>	655 uczestników badania PANDA	afektywne Go/NoGo + modele RL w RCT sertralina vs placebo	unimodalne tylko 54% przebiegów zadania było informatywnych; brak potwierdzenia prerejestrowanej hipotezy o Pavlovian inhibition; eksploracyjnie sertralina zwiększała szybkość uczenia z kar/strat	badanie podkreśla, że tłumaczenie modeli na klinikę wymaga zadań o wysokiej akceptowalności i rzetelności	[40]
ENIGMA CHR-P, 2024, <i>JAMA Psychiatry</i>	1 340 CHR-P i 1 237 zdrowych; 157 konwersji do psychozy	normative modeling morfometrii CT/SA/SV + klasyfikacja SVC	rozkłady były w dużej mierze zagnieżdżone w wariancji zdrowej populacji; AUC dla CHR-P vs zdrowi: 0,56 dla danych obserwowanych i 0,53 dla z-score; u konwertujących częściej występowały infranormalne wartości skroniowe	makroskalowa morfometria sama w sobie ma ograniczoną wartość jako biomarker diagnostyczny ryzyka psychozy	[41]
Mikus i wsp., 2025, <i>Biological Psychiatry</i>	45 zdrowych w teście–reteście, 437 osób online, 100 pacjentów ze schizofrenią	hierarchiczny model bayesowski uczenia o zmienności i szumie obserwacji	interclass correlations były umiarkowane–wysokie dla parametrów, a znakomite dla uśrednionych trajektorii przekonań i precision-weighted learning rates; niepewność co do zmienności wiązała się z cechami schizotypii i objawami pozytywnymi	dobrze skonstruowane modele bayesowskie mogą dawać stabilniejsze, bardziej symptom-specyficzne fenotypy obliczeniowe	[42]
Kadirvelu i wsp., 2026, <i>JMIR</i>	103 nastolatków; analiza główna 67 z aktywnymi i pasywnymi danymi; walidacja zewnętrzna 45	cyfrowe fenotypowanie smartfonowe + głębokie uczenie z contrastive pretraining	LOSO-CV dla danych łączonych: bAcc 0,71 (SDQ), 0,67 (bezsenność), 0,77 (myśli samobójcze), 0,70 (ED); w walidacji zewnętrznej 0,72/0,63/0,63/0,63; dla kilku wyników przewaga nad active-only była istotna, np. $P=.003$	smartfonowe dane aktywne i pasywne mogą dostarczać ekologicznie trafnych wskaźników ryzyka, ale wymagają ostrożnej walidacji i oceny fairness	[43]

Z przeglądu tych badań wyłania się spójny wzorec. **Najsilniejsze wyniki** osiągają modele łączące wiele źródeł informacji i uwzględniające czas - jak w prognostyce psychozy, predykcji odpowiedzi na sertralinę czy cyfrowym monitoringu. **Najcenniejsze wyniki mechanistyczne** pochodzą z dobrze zaprojektowanych zadań i modeli formalnych, które rozdzielają objawy na różne procesy uczenia i wnioskowania. **Najbardziej otrzeźwiające wyniki negatywne** pokazują zaś, że pojedyncza, statyczna modalność - zwłaszcza sama morfometria lub słabo działające zadanie - rzadko daje klinicznie dojrzały biomarker. [44]

Ograniczenia, etyka i przyszłość

Najważniejszym osiągnięciem psychiatrii obliczeniowej nie jest dziś jeszcze pełna automatyczna diagnostyka, lecz **przesunięcie poziomu opisu zaburzeń** - od etykiet diagnostycznych ku parametrom ukrytym, heterogeniczności jednostkowej i przewidywaniu przebiegu. Dzięki temu można pytać, czy dany pacjent ma przede wszystkim zaburzone uczenie od nagrody, przecenianie szumu sensorycznego, niestabilne przekonania o zmienności środowiska, czy może sieciowo zorganizowaną współchorobowość objawów. Duże otwarte zasoby i narzędzia normatywne dodatkowo umożliwiają opis odchyłeń jednostkowych względem szerokich referencji populacyjnych, a nie jedynie średnich grupowych. [45]

Jednocześnie ograniczenia są poważne i w znacznej mierze metodologiczne. Systematyczny przegląd modeli AI opartych na neuroobrazowaniu dla diagnoz psychiatrycznych objął 517 badań i 555 modeli; 83,1% modeli miało wysokie ogólne ryzyko biasu, 71,7% cierpiało na nieadekwatny rozmiar próby, 100% nie raportowało kalibracji, 99,1% niewystarczająco radziło sobie ze złożonością danych, a żaden model nie został uznany za gotowy do zastosowania klinicznego. Niezależnie od tego Flint i wsp. pokazali paradoks małych prób:

w neuroobrazowych badaniach depresji większe projekty dawały zwykle słabsze, ale bardziej wiarygodne wyniki niż wiele małych badań raportujących wysoką skuteczność. Do tego dochodzi problem psychometrii zadań - jak w badaniu PANDA, gdzie jedynie 54% przebiegów było wystarczająco informatywnych do wnioskowania modelowego. [46]

Ograniczenia nie są jednak wyłącznie techniczne. W cyfrowym fenotypowaniu i psychiatrii mobilnej szczególnie ostre są kwestie **zgody, prywatności, wtórnych użyc danych, ryzyka reidentyfikacji, asymetrii wiedzy między użytkownikiem a operatorem systemu oraz stroniczości algorytmicznej**. Delphi dotyczące etycznego rozwoju digital phenotyping wskazało zgodę, ochronę danych, bias i odpowiedzialność jako centralne obszary wymagające standardów. W UE na tę przestrzeń wchodzi już bezpośrednio trzy reżimy regulacyjne: GDPR dla danych osobowych i danych o zdrowiu, AI Act - który od 1 sierpnia 2024 r. obowiązuje jako ramy dla systemów AI, a dla medycznych systemów wysokiego ryzyka wymaga m.in. ograniczania ryzyka, wysokiej jakości zbiorów danych, przejrzystej informacji i nadzoru człowieka - oraz EHDS, której celem jest wspólna infrastruktura użycia i wymiany elektronicznych danych zdrowotnych w Europie. [47]

Przyszłość pola wydaje się należeć do pięciu kierunków. Po pierwsze, do **zadań bardziej ekologicznie trafnych** i wprost osadzonych w codziennym zachowaniu, nie tylko w laboratorium. Po drugie, do **hybryd mechanistyczno-predykcyjnych**: modeli, które są jednocześnie interpretowalne i użyteczne decyzyjnie. Po trzecie, do **walidacji prospektywnej i zewnętrznej**, z obowiązkową kalibracją i analizą fairness. Po czwarte, do **ciągłego fenotypowania** łączącego EMA, sensory i interwencje just-in-time. Po piąte, do **prywatności-preserving analytics**, w tym podejść federowanych i infrastrukturalnych zgodnych z regulacją europejską. Innymi słowy, najbardziej prawdopodobny scenariusz na najbliższe lata to nie „algorytm zastępujący psychiatrę”, lecz **system wspomagania decyzji klinicznych**, który łączy modele procesu, dane wielomodalne i ocenę lekarza. [48]

Piśmiennictwo

Adams RA, Huys QJM, Roiser JP. *Computational Psychiatry: Towards a Mathematically Informed Understanding of Mental Illness*. J Neurol Neurosurg Psychiatry. 2016;87:53–63.

Huys QJM, Maia TV, Frank MJ. *Computational Psychiatry as a Bridge From Neuroscience to Clinical Applications*. Nat Neurosci. 2016;19(3):404–413.

Montague PR, Dolan RJ, Friston KJ, Dayan P. *Computational Psychiatry*. Trends Cogn Sci. 2012.

Wang X-J, Krystal JH. *Computational Psychiatry*. Neuron. 2014.

Friston K. *The Free-Energy Principle: A Unified Brain Theory?* Nat Rev Neurosci. 2010;11:127–138.

Schultz W, Dayan P, Montague PR. *A Neural Substrate of Prediction and Reward*. Science. 1997;275:1593–1599.

Mathys CD, et al. *Uncertainty in Perception and the Hierarchical Gaussian Filter*. Front Hum Neurosci. 2014;8:825.

Brown VM, Zhu L, Solway A, et al. *Reinforcement Learning Disruptions in Individuals With Depression and Sensitivity to Symptom Change Following Cognitive Behavioral Therapy*. JAMA Psychiatry. 2021;78(10):1113–1122.

Koutsouleris N, Dwyer DB, Degenhardt F, et al. *Multimodal Machine Learning Workflows for Prediction of Psychosis in Patients With Clinical High-Risk Syndromes and Recent-Onset Depression*. JAMA Psychiatry. 2021;78(2):195–209.

Flint C, Cearns M, Opel N, et al. *Systematic Misestimation of Machine Learning Performance in Neuroimaging Studies of Depression*. Neuropsychopharmacology. 2021;46:1510–1517.

Martinez-Martin N, Greely HT, Cho MK. *Ethical Development of Digital Phenotyping Tools for Mental Health Applications: Delphi Study*. JMIR Mhealth Uhealth. 2021;9(7):e27343.

Watts D, Pulice RF, Reilly J, et al. *Predicting Treatment Response Using EEG in Major Depressive Disorder: A Machine-Learning Meta-Analysis*. Transl Psychiatry. 2022;12:332.

Tavares V, Vassos E, Marquand A, et al. *Prediction of Transition to Psychosis From an At-Risk Mental State Using Structural Neuroimaging, Genetic, and Environmental Data*. Front Psychiatry. 2023;13:1086038.

Chen Z, Liu X, Yang Q, et al. *Evaluation of Risk of Bias in Neuroimaging-Based Artificial Intelligence Models for Psychiatric Diagnosis: A Systematic Review*. JAMA Netw Open. 2023;6(3):e231671.

Markiewicz CJ, et al. *The OpenNeuro Resource for Sharing of Neuroscience Data*. eLife. 2021;10:e71774.

Poirot MG, Ruhe HG, Mutsaerts HJMM, et al. *Treatment Response Prediction in Major Depressive Disorder Using Multimodal MRI and Clinical Data: Secondary Analysis of a Randomized Clinical Trial*. Am J Psychiatry. 2024;181(3):223–233.

Malamud J, et al. *The Selective Serotonin Reuptake Inhibitor Sertraline Alters Aversive Reinforcement Learning in Depression and Anxiety: Secondary Analysis of the PANDA Trial*. Psychol Med. 2024.

ENIGMA Clinical High Risk for Psychosis Working Group. *Normative Modeling of Brain Morphometry in Clinical High Risk for Psychosis*. JAMA Psychiatry. 2024;81(1):77–88.

Mikus N, Lamm C, Mathys C. *Computational Phenotyping of Aberrant Belief Updating in Individuals With Schizotypal Traits and Schizophrenia*. Biol Psychiatry. 2025;97(2):188–197.

Kadirvelu B, Bellido Bel T, Freccero A, et al. *Digital Phenotyping for Adolescent Mental Health: Feasibility Study Using Machine Learning to Predict Mental Health Risk From Active and Passive Smartphone Data*. J Med Internet Res. 2026;28:e72501.

Piazza GG, Allegrini AG, Eley TC, et al. *Polygenic Scores and Networks of Psychopathology Symptoms*. JAMA Psychiatry. 2024;81(9):902–910.

Briganti G, Linkowski P, Fried EI. *Network Analysis: An Overview for Mental Health Research*. Psychol Med. 2024.

Yip SW, et al. *From Computation to Clinic*. Biol Psychiatry Glob Open Sci. 2023;3(3):296–308.

Vasilchenko KF, et al. *Current Status, Challenges and Future Prospects in Computational Psychiatry*. Consortium PSYCHIATRICUM. 2023.

OpenNeuro. *Official platform and dataset statistics*.

UK Biobank. *Official platform; 500,000 volunteers; 100,000-image milestone announcement, 2025*.

Adolescent Brain Cognitive Development Study. *Official study overview*; Dick AS, et al. *Meaningful Associations in the ABCD Study*. Dev Cogn Neurosci. 2021.

Human Connectome Project. *Connectome Coordination Facility overview*; Van Essen DC, et al. *The Human Connectome Project: A Data Acquisition Perspective*. NeuroImage. 2012.

NIMH Data Archive. *Official archive overview*.

ENIGMA Consortium. *Official consortium overview*.

PRONIA / NeuroMiner Model Library. *Personalised Prognostic Tools for Early Psychosis Management: official project description*.

CentileBrain / Ge R, et al. *Normative Modelling of Brain Morphometry Across the Lifespan With CentileBrain*. Lancet Digit Health. 2024.

Kato A, et al. *Computational Psychiatry Research Map (CPSYMAP)*. Front Psychiatry. 2020.

Translational Neuromodeling Unit, ETH/UZH. *Official mission statement*.

Max Planck UCL Centre for Computational Psychiatry and Ageing Research. *Official centre description*.

Applied Computational Psychiatry Lab, UCL / Max Planck UCL Centre. *Official research-group description*.

4C Computational Psychiatry Lab, UW–Madison. *Official lab description*.

Yale Computational Psychiatry Unit. *Official unit description*.

Center for Computational Psychiatry, Icahn School of Medicine at Mount Sinai. *Official research description*.

Centrum Sztucznej Inteligencji UAM. *Zespół Psychiatrii Obliczeniowej - oficjalny opis*.

Regulation (EU) 2016/679. *General Data Protection Regulation*.

Regulation (EU) 2024/1689. *Artificial Intelligence Act*.

European Commission. *European Health Data Space Regulation (EHDS)*.

[1] <https://pmc.ncbi.nlm.nih.gov/articles/PMC4717449/>

[2] [16] [22] [23] [32] [37] [44] <https://jamanetwork.com/journals/jamapsychiatry/fullarticle/2773732>

[3] [46] <https://jamanetwork.com/journals/jamanetworkopen/fullarticle/2801999>

[4] [9] [13] <https://pmc.ncbi.nlm.nih.gov/articles/PMC4237059/>

[5] Jakub Filip Możaryn, Anna Rebeka Szczegielniak, COMPUTATIONAL PSYCHIATRY: A BRIDGE BETWEEN TRANSLATION AND PRECISION, *International Journal of Neuropsychopharmacology*, Volume 28, Issue Supplement_1, February 2025, Pages i276–i277, <https://doi.org/10.1093/ijnp/pyae059.489>

[6] <https://csi.amu.edu.pl/zespoly/zespol-psychiatrii-obliczeniowej>

[7] Siegel S, Allan LG. The widespread influence of the Rescorla-Wagner model. *Psychon Bull Rev*. 1996 Sep;3(3):314-21. doi: 10.3758/BF03210755. PMID: 24213932. <https://pubmed.ncbi.nlm.nih.gov/24213932/>

[8] [25] <https://www.tnu.ethz.ch/en/home>

[10] [18] [24] [36] [45] <https://jamanetwork.com/journals/jamapsychiatry/fullarticle/2782452>

[11] <https://pubmed.ncbi.nlm.nih.gov/20068583/>

[12] <https://pubmed.ncbi.nlm.nih.gov/9054347/>

[14] <https://www.psycontrol-lab.de/>

[15] <https://pubmed.ncbi.nlm.nih.gov/39045106/>

[17] [41] <https://jamanetwork.com/journals/jamapsychiatry/fullarticle/2810624>

[19] [39] <https://pubmed.ncbi.nlm.nih.gov/38321916/>

[20] <https://pubmed.ncbi.nlm.nih.gov/35961967/>

[21] [43] <https://www.jmir.org/2026/1/e72501>

[26] <https://openneuro.org/>

[27] <https://www.ukbiobank.ac.uk/>

[28] <https://pmc.ncbi.nlm.nih.gov/articles/PMC8803401/>

[29] <https://www.humanconnectome.org/>

[30] <https://nda.nih.gov/>

[31] <https://enigma.ini.usc.edu/>

[33] <https://pmc.ncbi.nlm.nih.gov/articles/PMC6100771/>

[34] <https://pmc.ncbi.nlm.nih.gov/articles/PMC10705253/>

[35] <https://pmc.ncbi.nlm.nih.gov/articles/PMC7746554/>

[38] <https://www.frontiersin.org/journals/psychiatry/articles/10.3389/fpsy.2022.1086038/full>

[40] <https://pubmed.ncbi.nlm.nih.gov/38629200/>

[42] <https://pubmed.ncbi.nlm.nih.gov/39218138/>

[47] <https://mhealth.jmir.org/2021/7/e27343/>

[48] <https://www.sciencedirect.com/science/article/pii/S2667174322000507>

<https://csi.amu.edu.pl/zespoly/zespol-psychiatrii-obliczeniowej>