UNIWERSYTET VIZJA

PSYCHOLOGIA POZNAWCZA

Ćwiczenie laboratoryjne nr 5

Modele obliczeniowe poznania:

od danych do teorii – synteza całorocznego cyklu

Model dryfu decyzji | ACT-R | Sieci Bayesa | Synteza ćwiczeń 1–5

dr inż. Mateusz Pomianek

Przedmiot:	Psychologia poznawcza
Rok akademicki:	2024/2025
Semestr:	Zimowy / Letni – rok III (studia licencjackie)
Forma zajęć:	Ćwiczenia laboratoryjne (2 x 60 min = 120 min)
Metody:	Analiza modeli obliczeniowych, symulacja parametrów, synteza danych z Labs 1–4, dyskusja strukturowana
Materiały:	Wszystkie dane i materiały zamieszczone w tej instrukcji; kalkulator / arkusz kalkulacyjny
Grupa:	_____
Data:	_____

1. Informacje ogólne o zajęciach

Piąte i ostatnie ćwiczenia laboratoryjne zamykają roczny cykl, stawiając pytanie, które leży u serca współczesnej psychologii poznawczej: w jaki sposób możemy formalnie opisywać procesy umysłowe tak, by opis ten był ścisły, testowalny i generatywny? Modele obliczeniowe poznania to odpowiedź na to pytanie. Nie są to metafory ani luźne analogie do komputerów – to precyzyjne systemy równań, które pozwalają przewidywać zachowanie uczestników w warunkach, które jeszcze nie zostały przebadane.

Trzy modele są centralnym tematem dzisiejszych zajęć: model dryfu decyzji (DDM), architektura ACT-R oraz sieci Bayesa. Każdy z nich wyjaśnia inną klasę zjawisk poznawczych i jest powiązany z co najmniej jednym eksperymentem z Lab1w 1–4. Czwarte ćwiczenie to synteza całego cyklu: studenci w parach odwzorowują schematy powiązań między zjawiskami z pięciu laboratoriów i oceniają, który model najlepiej wyjaśnia zebrane dane.

Cele kształcenia (KRK – poziom 6. EQF)

Wiedza: Student opisuje założenia i parametry modelu dryfu decyzji (DDM), architektury ACT-R oraz sieci Bayesa; wyjaśnia pojęcia: przetwóg oczekiwany, gradient dryfu, next-fit, prior, likelihood, posterior; rozróżnia modele deskryptywne od normatywnych.

Umiejętności: Student dopasowuje parametry DDM do danych RT z Tabeli 1 metodą „na oko' i ocenia jakość dopasowania; oblicza wartości posterior przy prostych priorach i likelihood'ach; identyfikuje, który model najlepiej wyjaśnia konkretny zbiór danych z Labs 1–4; formułuje przynajmniej jedno falsyfikowalne przewidywanie modelu.

Kompetencje społeczne: Student krytycznie ocenia ograniczenia modeli obliczeniowych jako narzędzi naukowych; rozróżnia wyjaśnienie mechanistyczne od korelacyjnego; refleksyjnie podsumowuje kompetencje nabyte w cyklu pięciu laboratoriów.

1.1. Powiązanie z Labs 1–4 – mapa cyklu

Laboratorium	Temat	Główne zjawisko	Powiązany model obliczeniowy
Lab 1	Percepcja i uwaga	Efekt Stroopa, inattentional blindness, eye-tracking	Model dryfu decyzji (DDM) – czas reakcji jako wynik procesu akumulacji
Lab 2	Pamięć robocza	Span tasks, efekt pozycji seryjnej, ERP P300	ACT-R – moduł pamięci deklaratywnej; model buffer-u fonologicznego
Lab 3	Język i poznanie	Priming semantyczny, kategoryzacja kolorów, macierz podobieństwa	Sieci Bayesa – aktualizacja przekonań o przynależności kategorii
Lab 4	Heurystyki i błędy	Zakotwiczenie, CRT, błąd koniunkcji, atrybucja	Sieci Bayesa + DDM – porównanie wnioskowania normatywnego z opisowym
Lab 5	Modele obliczeniowe	Synteza: jak modele wyjaśniają dane z Labow 1–4	DDM, ACT-R, sieci Bayesa – porównanie i ocena

1.2. Harmonogram zajęć

Czas	Blok	Aktywność
0–10 min	Wprowadzenie	Cel i struktura ostatnich zajęć; mapa cyklu Labs 1–5
10–35 min	Wykład interaktywny	Model dryfu decyzji, ACT-R, sieci Bayesa – założenia i parametry
35–60 min	Ćw. 1 i 2	Ćw. 1: dopasowanie DDM do danych RT (Tabela 1); ćw. 2: obliczenia Bayesa (Tabela 2)
60—85 min	Ćw. 3	Analiza modelu ACT-R w świetle danych z Lab 2 (Tabela 3) i priming (Tabela 4)
85–110 min	Ćw. 4	Synteza cyklu: mapa powiązań, porównanie modeli, ewaluacja kompetencji
110–120 min	Dyskusja plenarna	Prezentacja map; pytania syntetyzujące; podsumowanie całego kursu

Wymagania wstępne

Przed zajęciami studenci powinni powtarzać podstawy rachunku prawdopodobieństwa: pojęcia zdarzenia, prawdopodobieństwo warunkowe, tw. Bayesa w najprostszej formie. Przydatna będzie umiejętność obliczania średnich i odchyleń standardowych. Nie jest wymagana znajomość programowania.

2. Podstawy teoretyczne

2.1. Czym są modele obliczeniowe poznania?

Model obliczeniowy to sformalizowany opis mechanizmu, który generuje obserwowane dane. Dobry model spełnia cztery kryteria: (a) przewiduje konkretne dane ilościowe, które można porównać z wynikami eksperymentów; (b) ma parametry o interpretacji psychologicznej; (c) jest falsyfikowalny: można wskazać dane, które go obalią; (d) jest generatywny: symuluje nowe dane w warunkach, które nie były częścią dopasowania.

Modele obliczeniowe różnią się od modeli statystycznych: model statystyczny opisuje wzór w danych (np. regresja), natomiast model obliczeniowy opisuje mechanizm wytwarzający ten wzór. Podejście obliczeniowe wyrósznicowuje trzy poziomy analizy (Marr, 1982): (1) obliczeniowy: co robi system i dlaczego?; (2) algorytmiczny: jak to robi, jakie reprezentacje i procedury są zaangażowane?; (3) implementacyjny: jak to jest zrealizowane fizycznie w mózgu?

2.2. Model dryfu decyzji (Drift Diffusion Model, DDM)

2.2.1. Założenia i parametry

Ratcliff (1978) zaproponował DDM jako opis procesu podejmowania binarnych decyzji poznawczych. Model zakłada, że decyzja jest wynikiem ciągłej akumulacji dowodów. Punkt startowy x0 drąży (driftuje) w kierunku jednej z dwóch granic decyzji (+a dla odpowiedzi „Tak' i 0 dla odpowiedzi „Nie') z pewnymi wahaniami losowymi. Czas reakcji to suma czasu procesu akumulacji i resztkowego czasu motorycznego T22.

Gradient dryfu	$v = (S - Szł) / (v_5 \cdot \sigma)$	v: sygnał / szum

Parametr	Symbol	Znaczenie psychologiczne	Typowy zakres
Próg decyzji	a	Ostrożność: szeroka granica = więcej dowodów wymaganych przed odpowiedzią; wysoka a = wolniejszy, dokładniejszy	0,05–0,30
Gradient dryfu	v	Jakość informacji: dodatni = ku odpowiedzi prawidłowej; ujemny = ku błędowi; |v| wysoki = łatwe zadanie	−2,0–2,0
Punkt startowy	z	Niezrównowazenie priorowe: z > a/2 = preferencja ku odpowiedzi Tak z wyprzedzeniem	0 – a
Czas nieodecyzyjny	T_{22}	Kodowanie sensoryczne + czas motoryczny; nie zależy od trudności zadania	150–300 ms
Rozproszenie dryfu	η	Zmienność uwagi miedzy próbami; im wyższy, tym bardziej rozrzucony rozkład RT	0,0–1,0

2.2.2. Przewidywania DDM dla danych z Lab 1

Model DDM przewiduje kilka wzorce, które można sprawdzić na danych Stroopa z Lab 1: (a) rozkład RT powinien być asymetryczny (sko1ny dodatni) z cienkimi ogonkami po lewej i grubymi po prawej; (b) średni RT i jego wariancja powinny rosnąć łącznie (efekt trudności zadania przesuwać oba jednocześnie); (c) związek między błędami a RT jest przewidywany przez model: trudne zadania generują błędy z dłuższymi RT (error-RT skewness pattern).

W warunkach efektu Stroopa z Lab 1 warunek niezgodny (incongruent) powinien odpowiadać niższemu gradientowi dryfu v (trudniejsza selekcja odpowiedzi) i/lub wyższemu progowi a (więcej wymaganego świadectwa). Oba warianty generują dłuższy średni RT, ale różne wariancje – co pozwala je odróżnić.

2.3. Architektura ACT-R

2.3.1. Moduły i reprezentacje

ACT-R (Adaptive Control of Thought – Rational; Anderson, 1983, 2007) to architektura kognitywna: kompletny system obliczeniowy opisujący poznanie jako współdziałanie wyspecjalizowanych modułów komunikujących się przez centralny bufor procedur. Kluczowe moduły to:

- **Moduł deklaratywny:** przechowuje pamięć faktyczną i semantyczną w postaci chunkow. Każdy chunk ma aktywację A, która maleje logarytmicznie z czasem (prawo potęgowe zapominania) i wzrasta z częstością i świeżością użycia.
- **Moduł proceduralny:** zawiera reguły produkcji (if–then); steruje przepływem informacji między modułami; jeden cykl produkcji trwa ok. 50 ms.
- **Moduł wzrokowo-przestrzenny:** odwzorowuje fiksacje i uwagę wzrokową; bezpośrednio powiązany z danymi eye-tracking z Lab 1.
- **Moduł motoryczny:** planuje i wykonuje reakcje; czas inicjacji odpowiedzi wynosi ok. 50–200 ms w zależności od złożoności ruchu.

2.3.2. Aktywacja chunków i czas pamięci roboczej

Aktywacja chunką i (A_i) w module deklaratywnym jest wyznaczana przez:

Aktywacja ACT-R	$A_i = B_i + \Sigma W_k \cdot S_{ki}$	B: bazowa, W: waga kontekstu

Gdzie B_i to aktywacja bazowa (rośnie z częstością użycia, maleje logarytmicznie z czasem), W_k to wagi kontekstowe (jak bardzo bodziec k jest aktywny w buforze), a $S_{k\ i}$ to siła skojarzenia między k a i. Czas pobierania chunku to:

Czas pobierania	$T = F \cdot e^{(-f \cdot A_i)}$	F = 1,0 s (typowe)

Przewidywanie dla danych z Lab 2: efekt pozycji seryjnej wynika z różnych aktywacji chunków: elementy z początku listy mają wyższą B_i (więcej czasu na rehearsal), elementy z końca są najbardziej świeże. Elementy ze środka mają ani wyższą B_i, ani najwyższą świetność – co odpowiada niższym odsetkom przypomnień obserwowanym w Tabeli 2 z Lab 2.

2.4. Sieci Bayesa i poznanie probabilistyczne

2.4.1. Twierdzenie Bayesa w poznaniu

Bayesowski model poznania postuluje, że umysł działa jak optymalne urządzenie wnioskujące: aktualizuje przekonania (prior beliefs) w oparciu o nowe dane (likelihood), wytwarzając zaktualizowane przekonania (posterior beliefs). Formalna wersja:

Twierdzenie Bayesa	$P(H\|D) = P(D\|H) \cdot P(H) / P(D)$	H = hipoteza; D = dane

W języku poznawczym: P(H) to wcześniejsze przekonanie o hipotezie (np. „to słowo jest powiązane semantycznie'), P(D|H) to prawdopodobieństwo obserwowania tych danych przy prawdziwej hipotezie (likelihood), a P(H|D) to zaktualizowane przekonanie po obserwacji. Bayesowski uczestnik eksperymentu primingowego z Lab 3 aktualizuje prawa dostępności słów powiązanych semantycznie za każdym razem, gdy pryma jest skojarzona z celem.

2.4.2. Model Bayesa a błąd koniunkcji

Błąd koniunkcji z Lab 4 (zadanie Lindy) można opisać jako odchylenie od bayesowskiego optymum: uczestnik używa likelihood P(opis|Linda jest kasjerką i feministką) zamiast posterior P(Linda jest kasjerką i feministką | opis), ignorując prior P(Linda jest feministką) – który jest mniejszy niż P(Linda jest kasjerką). Formalnie: ludzie odwracają kolejność warunkowania, co daje intuicyjnie błędne, lecz „pasujące' wrażenie.

3. Ćwiczenia

Ogólne zasady pracy

Pracujecie w stałych parach przez całe zajęcia. Ćwiczenie 4 jest wyjątkiem: syntetyczne mapy można tworzyć indywidualnie lub w parach, a potem porównywać z innymi.

Nie zniechęcajcie się matematyką. Obliczenia w tym ćwiczeniu są proste (mnożenie, dzielenie, potęgowanie). Każdy krok jest szczegółowo opisany z przykładami.

Celem nie jest uzyskanie idealnych wyników, lecz zrozumienie: co model mówi o danych i gdzie model zawodzi. Rozbieżności między modelem a danymi są tak samo interesujące jak zgodności.

Ćwiczenie 1: Dopasowanie modelu dryfu decyzji do danych Stroopa

Tabela 1 zawiera dane z zadania Stroopa (12 uczestników, warunki congruent i incongruent). Twoim celem jest rozumienie, jak parametry DDM przekladaja się na obserwowalne miary (RT, dokładność) i ręczne wyprobowanie, ktore ustawienia parametrów dobrze opisują dane.

Tabela 1. Dane RT z zadania Stroopa (warunki congruent i incongruent, n = 12)

Uczestnik	RT congruent (ms)	SD congruent	RT incongruent (ms)	SD incongruent	delta-RT (ms)	% bledow incon.
P01	512	68	578	89	66	5
P02	498	72	561	95	63	6
P03	527	65	592	102	65	4
P04	541	81	618	113	77	8
P05	489	59	554	84	65	5
P06	518	74	587	97	69	6
P07	534	83	612	118	78	9
P08	505	69	572	91	67	5
P09	552	88	631	122	79	10
P10	496	64	558	87	62	4
P11	523	77	591	104	68	7
P12	509	71	576	93	67	5
SREDNIA	517	73	586	99	68	6,2
SD (miedzy ucz.)	18	8	24	13	6	2,0

Instrukcja krok po kroku

1

Oblicz rozkład RT i porównaj warunki

Na podstawie Tabeli 1 (wiersze P01–P12, bez wiersza SREDNIA) oblicz:

Warunek congruent: średnią (M_con) i odchylenie standardowe (SD_con) z 12 wartości RT. Warunek incongruent: średnią (M_incon) i SD_incon z 12 wartości RT.

Porównaj swoje obliczenia z wierszem SREDNIA w Tabeli 1 (tam są podane wartości wzorcowe). Oblicz stosunek SD_incon / SD_con. Wartość większa niż 1,0 oznacza, że warunek incongruent jest bardziej zmienny. Wpisz wynik do sekcji 4.1.

2

Zinterpretuj dane w języku DDM – który parametr się zmienia?

DDM ma kilka parametrów, które mogą wyjaśnić różnicę między warunkami. Przeanalizuj każdą hipotezę:

Hipoteza A – niższy gradient dryfu (v) w warunku incongruent: trudniejsza selekcja informacji powoduje wolniejszą akumulację dowodów. Przewidywanie: dłuższy średni RT i wyższy % błędów.

Hipoteza B – wyższy próg decyzji (a) w warunku incongruent: uczestnik wymaga więcej dowodów, zanim odpowie. Przewidywanie: dłuższy RT, ale niższy % błędów.

Patrz na dane z Tabeli 1: średni RT jest dłuższy w warunku incongruent (586 vs 517 ms), ale % błędów też jest wyższy (6,2%). Która hipoteza (A czy B) lepiej pasuje do tych danych? Wpisz odpowiedź do sekcji 4.1.

3

Symulacja ręczna: oblicz przewidywany średni RT z DDM

DDM przewiduje średni RT według wzoru uproszczonego (Ratcliff i McKoon, 2008):

$RT_śr = T_{22} + (a / 2v) \cdot [1 - e^{(-2vz/a^2)}]$

Dla warunku congruent: przyjmij T_{22} = 200 ms, v = 0,35, a = 0,12, z = a/2 = 0,06.

Wylicz krok po kroku: (a) 2v = 0,70; (b) $2vz/a^2 = 0{,}70 \times 0{,}06 / 0{,}0144 = 2{,}92$; (c) $e^{(-2{,}92)} \approx 0{,}054$; (d) 1 – 0,054 = 0,946; (e) a/(2v) = 0,12/0,70 = 0,171 s; (f) RT = 0,200 + 0,171 × 0,946 = 0,362 s = 362 ms.

Uwaga: wynik 362 ms jest niższy niż obserwowane 517 ms. Oznacza to, że nasze założone parametry są złe lub uproszczenie modelu nie oddaje pełnego obrazu. Spróbuj

powiększyć T22 do 350 ms (realistyczne dla nazyw ania koloru) i ponownie oblicz. Które T22 daje wynik bliższy 517 ms?

4

Oblicz przwidywany delta-RT dla warunku incongruent

Dla warunku incongruent przyjmij tę samą T22 co w kroku 3, ale zmniejsz gradient dryfu: v = 0,22 (niższy, bo trudniejsza selekcja). Zachowaj a = 0,12, z = 0,06.

Oblicz RT_incon wg tego samego wzoru. Następnie oblicz przewidywany delta-RT = RT_incon – RT_con.

Porównaj z obserwowanym delta-RT = 68 ms (wiersz SREDNIA Tabeli 1). Ile wynosi Twoje przewidywanie? O ile odbiega od danych?

Jaka zmiana parametrów (v, a, T22) zmniejszyłaby tę rozbieżność? Wpisz hipotezę do sekcji 4.1.

5

Ocena jakości dopasowania i ograniczeń modelu

Model DDM uproszczony w kroku 3 prawdopodobnie nie trafił dokładnie w obserwowane średnie. To normalne – w prawdziwym badaniu stosuje się numeryczne metody optymalizacji (MCMC, gradient descent).

Na podstawie Twoich obliczeń wpisz do sekcji 4.1: (a) które parametry DDM są najbardziej wrażliwe na zmianę warunku? (b) czego DDM NIE wyjaśnia w danych Stroopa z Lab 1? (np. efekt praktyki, różnice indywidualne niewyjaśnione przez v i a).

Ćwiczenie 2: Obliczenia Bayesowskie – aktualizacja przekonań

Tabela 2 zawiera pięć scenariuszy z danych różnych Lab lub klasycznych przykadłów. Dla każdego obliczysz wartość posterior P(H|D) ze wzoru Bayesa oraz ocenisz, jak prior i likelihood wpływają na wynik.

Tabela 2. Scenariusze do obliczeń bayesowskich (wartosci prior i likelihood).

Scenariusz	Hipoteza H	Prior P(H)	Likelihood P(D|H)	Likelihood P(D|nie-H)	Posterior P(H|D)
B1: Diagnoza (rzadka choroba)	Pacjent ma chorobę X	0,01	0,95	0,05	do obliczenia
B2: Priming sem. (Lab 3)	Słowo powiązane semantycznie	0,30	0,85	0,40	do obliczenia
B3: Kategoryzacja barw	Bodziec międzykategorialny	0,50	0,70	0,30	do obliczenia
B4: Zakotwiczenie (Lab 4)	Uczestnik z grupy wysok. kotwy	0,50	0,65	0,45	do obliczenia
B5: FAE (Lab 4)	Esej wyraża praw. poglądy	0,40	0,80	0,35	do obliczenia

Instrukcja krok po kroku

1

Zrozum wzor i naucz się go stosować na przykładzie B1

Wzor Bayesa: P(H|D) = P(D|H) · P(H) / P(D)

P(D) obliczamy jako świadectwo totalne: P(D) = P(D|H) · P(H) + P(D|nie-H) · P(nie-H)

Przykład B1 (diagnoza): P(H) = 0,01; P(D|H) = 0,95; P(nie-H) = 0,99; P(D|nie-H) = 0,05

Krok a: P(D) = 0,95 × 0,01 + 0,05 × 0,99 = 0,0095 + 0,0495 = 0,059

Krok b: P(H|D) = (0,95 × 0,01) / 0,059 = 0,0095 / 0,059 = 0,161 ≈ 16,1%

Wynik jest zaskakujący: mimo testu o 95% czułości, prawdopodobieństwo faktycznej choroby po jednym wyniku pozytywnym to tylko 16%! To dlatego, że prior (choroba rzadka) silnie ciągnie posterior w dół. Wpisz ten wynik do sekcji 4.2 jako wzorcowy.

2

Oblicz posterior dla scenariuszy B2–B5

Dla każdego scenariusza (B2, B3, B4, B5) powtarz ten sam schemat:

1. Odczytaj P(H), P(D|H), P(D|nie-H) z Tabeli 2.
2. Oblicz P(nie-H) = 1 – P(H).
3. Oblicz P(D) = P(D|H) · P(H) + P(D|nie-H) · P(nie-H).
4. Oblicz P(H|D) = P(D|H) · P(H) / P(D).

Wpisz wszystkie 5 wyników do tabeli w sekcji 4.2.

3

Analiza wpływu prioru

Wybierz scenariusz B2 (priming semantyczny). Zmień prior P(H) trzy razy i za każdym razem oblicz nowy posterior:

Wersja 1: P(H) = 0,10 (rzadkie powiązania)

Wersja 2: P(H) = 0,30 (oryginalna wartość)

Wersja 3: P(H) = 0,70 (częste powiązania)

Narysuj wykres: posterior (oś Y) jako funkcja prioru (oś X) dla tych trzech wartości plus ewentualnych dodatkowych. Jak bardzo prior przesuwają posterior? Wpisz wniosek do sekcji 4.2.

4

Powiąż wyniki z błędem koniunkcji z Lab 4

Scenariusz B5 odpowiada sytuacji z zadania Lindy (Lab 4, scenariusz S1). Prior P(H) = 0,40 to prawdopodobieństwo bycia feministką.

Oblicz posterior P(H|opis Lindy). Czy wynik jest wyższy czy niższy niż prior?

Teraz oblicz prawdopodobieństwo koniunkcji: P(kasjerka I feministka). Jeśli P(kasjerka) = 0,90 i P(feministka|opis) to obliczone wyżej, to P(kasjerka I feministka) = P(kasjerka) × P(feministka|opis) = ...

Porównaj z P(kasjerka) = 0,90. Co to mówi o błędzie koniunkcji? Dlaczego intuicja zawodzi mimo prostych obliczeń? Wpisz interpretację do sekcji 4.2.

Ćwiczenie 3: ACT-R i dane z pamięci roboczej oraz primingu

W tym ćwiczeniu sprawdzasz, czy model ACT-R (zakładający aktywację chunków malejącą z czasem i rosnącą z częstością) trafnie przewiduje dwa rodzaje danych: krzywą pozycji seryjnej z Lab 2 (Tabela 3) i efekty primingu z Lab 3 (Tabela 4).

Tabela 3. Symulowane aktywacje ACT-R i przewidywane czasy pobierania dla 12 pozycji listy słów

Pozycja	Aktywacja bazowa B	Swieezosc (t od enc. w s)	Aktywacja A (symulowana)	Przewidyw. czas pobier. (ms)	Obs. % poprawnych (Lab 2 war. A)
1	1,80	120	2,10	122	82
2	1,60	112	1,88	153	76
3	1,40	104	1,65	190	64
4	1,20	96	1,43	238	55
5	1,10	88	1,28	278	48

Pozycja	Aktywacja bazowa B	Swieezosc (t od enc. w s)	Aktywacja A (symulowana)	Przewidyw. czas pobier. (ms)	Obs. % poprawnych (Lab 2 war. A)
6	1,00	80	1,15	317	44
7	1,00	72	1,10	333	46
8	1,05	64	1,10	333	52
9	1,20	56	1,22	295	61
10	1,30	48	1,32	267	70
11	1,50	40	1,52	219	79
12	1,80	32	1,78	168	91

Tabela 4. Porównanie przewidywan ACT-R (na podstawie sily skojarzenia S) z obserwowanymi efektami primingu z Lab 3.

Para słów	Siła skojarzenia S (szac.)	Przewidyw. delta-RT DDM (ms)	Obs. delta-RT Lab 3 (ms)	Zgodność predykcji (%)
PIES – KOT	2,10	72	66	92
BANAN – JABŁKO	2,05	68	71	96
LEKARZ – SZPITAL	2,20	76	69	91
WODA – RZEKA	2,15	73	73	100
CZARNY – BIAŁY	2,30	80	85	94
MATKA – OJCIEC	2,25	78	67	86
MUZYKA – MELODIA	1,95	62	62	100
ZIMA – Śnieg	2,28	79	81	97

Instrukcja krok po kroku

1

Narysuj krzywę pozycji seryjnej: dane vs model ACT-R

Utwórz wykres liniowy z pozycją (1–12) na osi X.

Nanieś dwie linie: (a) obserwowany % poprawnych (kolumna 6 Tabeli 3 – dane z Lab 2, warunek A); (b) przewidywania ACT-R – zamien czas pobierania na skale procentową: im krótszy czas pobierania, tym wyższy % poprawnych. Skorzystaj ze wzoru: % = 100 – (T_pobierania – T_min) / (T_max – T_min) × 100, gdzie T_min = 122 ms, T_max = 333 ms. Opisz obie linie w legendzie. Dodaj tytuł wykresu.

2

Ocen jakość dopasowania modelu ACT-R

Dla każdej z 12 pozycji oblicz różnicę: Dane – Predykcja ACT-R (w punktach procentowych). Wpisz do tabeli w sekcji 4.3.

Oblicz średnią bezwzględną różnicę (MAE = mean absolute error) ze wzoru: MAE = suma |Data_i – Pred_i| / 12.

Im niższy MAE, tym lepsze dopasowanie. Typowe dobre dopasowanie w modelowaniu psychologicznym to MAE < 5 punktów proc. Czy Twój wynik spełnia to kryterium?

3

Zidentyfikuj miejsca niedopasowania

Które pozycje listy są najgorzej przewidywane przez ACT-R (najwyższa bezwzględna różnica)?

Wśród typowych niedopasowań ACT-R dla tego zadania: (a) efekt pierwszeństwa jest przez ACT-R często niedoszacowywany, bo model nie uwzględnia strategicznego rehearsalu; (b) efekt świeżości jest dobrze przewidywany przez aktywację bazową.

Czy to samo widać w Twoim wykresie? Wpisz obserwację do sekcji 4.3.

4

Analiza Tabeli 4 – ACT-R i priming semantyczny

Tabela 4 zawiera 8 par słów z Lab 3 z szacunkowymi siłami skojarzenia S (wyznaczonymi przez ACT-R jako log częstości współwystępowania w korpusie), przewidywanym delta-RT (z modelu) i obserwowanym delta-RT z Lab 3.

Oblicz korelację Pearsona między kolumną „Przewidywany delta-RT' a „Obserwowany delta-RT' ze wszystkich 8 par. Wpisz r do sekcji 4.3.

Czy korelacja jest silna? Interpretuj według Cohena. Która para ma najgorsze przewidywanie (najwyższa % niezgodność w kol. 5)? Co mogło spowodować tę rozbieżność?

5

Porównaj DDM z ACT-R dla tych samych danych primingu

I DDM, i ACT-R przewidują efekty primingu, ale przez różne mechanizmy: DDM przez zmianę gradientu dryfu v (powiązany pryma zwiększa v), ACT-R przez pre-aktywację chunku celu (wyższa A_i → krótszy czas pobierania → krótszy RT).

Oba modele przewidują tę samą kierunkową zmianę RT. Jakie dane empiryczne mogłyby odróżnić te dwa wyjaśnienia? Podpowiedź: pomyśl o rozkładzie RT (nie tylko średni) i o warunkach obciążenia pamięci roboczej.

Wpisz hipotezę empiryczną (1–2 zdania) do sekcji 4.3.

Ćwiczenie 4: Synteza cyklu – mapa powiązań i ewaluacja kompetencji

Cel ćwiczenia 4

To ostatnie ćwiczenie całego rocznego cyklu laboratoriów. Jego celem nie jest obliczanie ani analiza nowych danych, lecz integracja: połączenie wszystkich zjawisk, modeli i metod z Labs 1–5 w jeden spójny obraz.

Efektem czywieczenia jest ręcznie narysowana lub schematyczna mapa powiązań (concept map), która zostanie zaprezentowana na forum grupy. Każda para przedstawia swoją mapę w 2–3 minutach.

Instrukcja krok po kroku

1

Zbierz materiał – lista zjawisk z pięciu labora toriów

Na osobnej kartce (lub w arkuszu) wypisz kolumna po kolumnie wszystkie główne zjawiska i efekty z każdego laboratorium:

Lab 1: efekt Stroopa, delta-RT, inattentional blindness, fiksacja, sakkada, pop-out vs conjunction search, Load Theory

Lab 2: digit span, efekt pozycji seryjnej (primacy, recency), amplituda P300, zadanie n-back, pętla fonologiczna, notatnik wzrokowo-przestrzenny, centralny system wykonawczy

Lab 3: priming semantyczny, efekt primingu (delta-RT), macierz podobieństwa, efekt kategorialny barw, model Collins i Loftus, hipoteza Whorfa

Lab 4: efekt zakotwiczenia (AEI), wynik CRT, błąd koniunkcji, heurystyka dostępności, FAE, System 1, System 2

Lab 5: gradient dryfu (v), próg decyzji (a), T22, aktywacja ACT-R (A_i), siła skojarzenia (S), prior, posterior, twierdzenie Bayesa

2

Zidentyfikuj powiązania między zjawiskami

Dla każdej pary zjawisk z różnych Labów, między którymi widać powiązanie, narysuj strzałkę i opisz relację jedną–2 słowami.

Przykłady gotowych powiązań do umieszczenia na mapie:

efekt Stroopa → gradient dryfu v: warunek incon. niższy v

efekt pozycji seryjnej → aktywacja ACT-R B: świeżość wyjaśnia recency

priming semantyczny → pre-aktywacja ACT-R: pryma zwiększa A_i celu

błąd koniunkcji → Bayes: ignorowanie prioru; odchylenie od P(H|D)

CRT → System 2 → pamięć robocza: wyższy CRT = lepsza kontrola S2 = większa pojemność PR

heurystyka dostępności → siec semantyczna: łatwość przypomnienia ~ siła skojarzenia S inattentional blindness → Load Theory → późne filtrowanie uwagi

3

Narysuj mapę konceptualną

Na dużym arkuszu (A4 lub A3) umieść pięć węzłów centralnych: Lab 1, Lab 2, Lab 3, Lab 4, Lab 5. Każdy węzeł otocz głównymi zjawiskami jako węzłami satelitarnymi. Połącz zjawiska strzałkami międzylaboratoryjnymi. Użyj różnych kolorów lub linii ciągłych / przerywanych dla różnych rodzajów relacji (np. linia ciągła = jeden model wyjaśnia oba; linia przerywana = analogia lub powiązanie empiryczne). Umieść trzy modele (DDM, ACT-R, Bayes) w centrum lub jako warstwę „wyjaśniającą' pod zjawiskami. Każdy model powinien mieć strzałki do zjawisk, które wyjaśnia. Podpisz mapę nazwiskami pary i Lab 5.

4

Odpowiedz na pytania syntetyczne

Na podstawie swojej mapy odpowiedz na trzy pytania syntetyczne (wpisz do sekcji 4.4):

Pytanie 1: Które zjawisko z Labs 1–4 jest Twoim zdaniem najlepiej wyjaśnione przez modele obliczeniowe, a które najgorzej? Uzasadnij.

Pytanie 2: Czy istnieje jedno zjawisko „kluczowe' na Twojej mapie, które łączy się z naj większą liczbą innych zjawisk? Jakie to zjawisko i co mówi o architekturze systemu poznawczego?

Pytanie 3: Jeśli miałbyś zaproponować szóste laboratorium do tego cyklu, jakie zjawisko poznawcze byś zbadał i który model obliczeniowy wykorzystałbyś? Uzasadnij.

5

Ewaluacja własnych kompetencji

Wypełnij tabelę samooceny w sekcji 4.4. Dla każdego z pięciu laboratoriów oceń na skali 1–5, jak dobrze opanowałeś: (a) treść teoretyczną; (b) umiejętność analizy danych; (c) rozumienie powiązań z innymi Lababami.

Zaznacz jedną kompetencję, którą chcesz dalej rozwinąć po ukończeniu kursu. Wpisz konkretny krok, jaki podejmiesz (artykuł do przeczytania, narzędzie do wypróbowania, kurs online). To ostatni wpis w rocznym cyklu labów. Dobrze wykonana mapa i refleksja są dowodem kompetencji, które wykraczają daleko poza znajomość definicji.

4. Arkusze wyników – do wypełnienia podczas zajęć

Imię i nazwisko:	
Numer albumu:	
Partner analityczny:	

Data zajęć:	

4.1. Wyniki ćwiczenia 1 – DDM

Ddm – obliczenia i interpretacja	Odpowiedz / wyniki
M_con i SD_con obliczone (z P01–P12):	M = ____ms; SD = ____ms
M_incon i SD_incon obliczone:	M = ____ms; SD = ____ms
Stosunek SD_incon / SD_con:	wartość > 1 = większa zmienność warunku incongruent
Hipoteza A (niższy v) czy B (wyższy a) – lepsza zgodna z danymi?	uzasadnij w 2 zdaniach
Przewidywany RT_con ze wzoru DDM (T_{22} = 350 ms):	ms (oblicz)
Przewidywany RT_incon (v = 0,22):	ms (oblicz)
Przewidywany delta-RT vs obserwowany (68 ms):	różnica: ____ms
Parametr najbardziej wrażliwy na zmianę warunku:	
Co DDM nie wyjaśnia w danych Stroopa:	

4.2. Wyniki ćwiczenia 2 – Obliczenia Bayesa

Scenariusz	P(H)	P(D|H)	P(D|nie-H)	P(D) = ...	Posterior P(H|D)
B1 (choroba)	0,01	0,95	0,05		
B2 (priming)	0,30	0,85	0,40		
B3 (barwy)	0,50	0,70	0,30		
B4 (kotwica)	0,50	0,65	0,45		
B5 (FAE)	0,40	0,80	0,35		

Bayes – analiza dodatkowa	Odpowiedz / wyniki
Posterior B2 przy P(H) = 0,10:	
Posterior B2 przy P(H) = 0,30 (oryginalny):	
Posterior B2 przy P(H) = 0,70:	
Wniosek o wpływie prioru na posterior:	
P(kasjerka I feministka) po obliczeniu posteriorowego P(feminizm):	
Interpretacja błędu koniunkcji w języku Bayesa:	

4.3. Wyniki ćwiczenia 3 – ACT-R

Pozycja	Obs. % Lab 2	Pred. % ACT-R	Różnica |Obs – Pred|
1	82		
2	76		
3	64		
4	55		
5	48		
6	44		
7	46		
8	52		
9	61		
10	70		
11	79		
12	91		
SUMA |różnic|			

ACT-R – analiza	Odpowiedz / wyniki
MAE (Mean Absolute Error):	pkt proc.
Spełnia kryterium MAE < 5?	tak / nie
Pozycje najgorzej przewidywane (najwyższa różnica):	
Który efekt (primacy czy recency) jest niedopasowany?	
Korelacja przewidywany vs obserwowany delta-RT (Tabela 4):	r = ____; interpretacja: ____
Para z najgorsze dopasowaniem i hipoteza dlaczego:	
Jak odróżnić DDM od ACT-R na podstawie danych RT?	

4.4. Wyniki ćwiczenia 4 – Synteza i samoocena

Pytania syntetyczne	Odpowiedz / wyniki
Zjawisko najlepiej wyjaśnione przez modele obliczeniowe:	
Zjawisko najgorzej wyjaśnione przez modele:	
Zjawisko „kluczowe' na mapie (naj więcej połączeń):	
Co mowi to o architekturze systemu poznawczego:	
Propozycja Lab 6 – temat i model:	

Laboratorium	Treść teoret. (1–5)	Analiza danych (1–5)	Powiązania (1–5)	Komentarz / co chcę poprawić
Lab 1 – Percepcja i uwaga				
Lab 2 – Pamięć robocza				
Lab 3 – Język i poznanie				
Lab 4 – Heurystyki				
Lab 5 – Modele oblicz.				

Plan rozwoju po kursie	Odpowiedz / wyniki
Jedna kompetencja do dalszego rozwoju:	
Konkretny krok, który podejmę (artykuł / kurs / projekt):	

5. Protokół analityczny – pytania do dyskusji plenarnej

5.1. Modele obliczeniowe i ich ograniczenia

Nr	Pytanie analityczne	Odpowiedz / Notatka
1	DDM, ACT-R i sieci Bayesa to trzy różne podejścia do modelowania poznania. Dla którego zjawiska z Labs 1–4 każdy z tych modeli byłby najbardziej odpowiedni? Podaj uzasadnienie dla każdego modelu oddzielnie.	
2	Twoje obliczenia DDM w ćwiczeniu 1 prawdopodobnie nie trafiły dokładnie w dane. Wymień trzy przyczyny, dla których uproszczony wzor analityczny nie wystarcza do dopasowania modelu w praktyce. Jakie narzędzia (programistyczne, statystyczne) są do tego potrzebne?	
3	Model ACT-R zakłada, że efekt pozycji seryjnej wynika z różnic aktywacji. Model Baddeleya z Lab 2 wyjaśnia ten efekt przez różne subsystemy (rehearsal, bufor). Czy oba wyjaśnienia są sprzeczne, komplementarne czy jedno z nich implikuje drugie? Uzasadnij.	

5.2. Bayes i odchylenia od optymalnego wnioskowania

Nr	Pytanie analityczne	Odpowiedz / Notatka
1	Błąd koniunkcji (Lab 4) można opisać jako odwrotność twierdzenia Bayesa: uczestnik używa likelihood zamiast posterior. Jak bardzo musiałby się różnić prior (baza, że ktoś jest kasjerką), aby bayesowski posterior był równoznaczny z intuicyjną odpowiedzią uczestnika? Oblicz próg prioru.	
2	Gigerenzen argumentuje, że ludzie są dobrymi bayesistami w formacie częstotliwościowym. Zaprojektuj wersję scenariusza B1 (diagnoza) wyrażnistą w sposób częstotliwościowy zamiast procentowego. Czy Twoim zdaniem ta zmiana formatu zmniejszyłaby błąd?	

5.3. Synteza cyklu Labs 1–5

Nr	Pytanie analityczne	Odpowiedz / Notatka
1	Każdy z pięciu labów badał inny „poziom' systemu poznawczego: od automatycznych proce sów percepcyjnych (Lab 1) przez pamięć i język (Labs 2–3) po myślenie i modele (Labs 4–5). Jaki ogólny wniosek o architekturze systemu poznawczego wypływa z całego cyklu? Sformułuj jedno zdanie ogólne.	
2	Czy badania laboratoryjne (kontrola zmiennych, próby izolowane) są najlepszym sposobem badania poznania? Jakie „realnosc' brakuje w paradygmatach z Labs 1—5 i jak można by ją przywrucić metodologicznie? Odwołaj się do pojęcia trafności ekologicznej.	
3	Wyniki z którego laboratorium są Twoim zdaniem najbardziej zaskakujące, a z którego najbardziej oczywiste po kursie? Czy przed tym kursem przewidywałbyś te wyniki?	

6. Literatura

6.1. Literatura obowiązkowa

1. **Anderson, J. R. (2007).** How Can the Human Mind Occur in the Physical Universe? Oxford University Press. [Rozd. 1–3: Architektura ACT-R]
2. **Ratcliff, R. i McKoon, G. (2008).** The diffusion decision model: Theory and data for two-choice decision tasks. Neural Computation, 20(4), 873–922.
3. **Griffiths, T. L., Chater, N., Kemp, C., Perfors, A. i Tenenbaum, J. B. (2010).** Probabilistic models of cognition: Exploring representations and inductive biases. Trends in Cognitive Sciences, 14(8), 357–364.
4. **Nęcka, E., Chwila, J. i Szymura, B. (2013).** Psychologia poznawcza. PWN. [Rozdział 11: Modele poznania]

6.2. Literatura uzupełniająca

5. **Marr, D. (1982).** Vision: A Computational Investigation into the Human Representation and Processing of Visual Information. MIT Press. [Rozdział 1: Trzy poziomy opisu]
6. **Ratcliff, R. (1978).** A theory of memory retrieval. Psychological Review, 85(2), 59–108.
7. **Anderson, J. R. i Lebiere, C. (1998).** The Atomic Components of Thought. Erlbaum.
8. **Tenenbaum, J. B., Kemp, C., Griffiths, T. L. i Goodman, N. D. (2011).** How to grow a mind: Statistics, structure, and abstraction. Science, 331(6022), 1279–1285.
9. **Voss, A., Rothermund, K. i Voss, J. (2004).** Interpreting the parameters of the diffusion model: An empirical validation. Memory and Cognition, 32(7), 1206–1220.
10. **Gigerenzen, G. i Hoffrage, U. (1995).** How to improve Bayesian reasoning without instruction: Frequency formats. Psychological Review, 102(4), 684–704.