

Nowoczesne technologie i narzędzia cyfrowe w badaniach psychologicznych

Od pomysłu do publikowalnego eksperymentu

dr inż. Mateusz Pomianek

MAPA WYKŁADU

Pięć etapów cyfrowego badania empirycznego

01

Projektowanie

Pytania badawcze
Hipotezy
Preregistracja

02

Pomiar

Narzędzia
eksperymentalne
Źródła danych
Precyzja pomiaru

03

Automatyzacja

Workflow
Logowanie
Kontrola jakości

04

Analiza

Statystyki
klasyczne,
ML / AI
Modelowanie

05

Publikacja

Otwarta nauka
Kod i dane
Replikowalność

Każdy etap kończy się konkretnymi narzędziami lub procedurą wdrożeniową

PSYCHOLOGIA JAKO NAUKA POMIAROWA

KONSTRUKT psychologiczny

(np. uwaga, emocja, lęk, motywacja)

operacjonalizacja

● Czas reakcji

ms, precyzja sprzętowa

● Ruch oczu

fiksacje, sakkady

● Mimika

AU, FACS, landmarki

● Głos i mowa

prozodia, MFCC

● Fizjologia

EDA, HRV, EEG

● Dane kontekstowe

lokalizacja, aktywność

Wybór miary to decyzja teoretyczna, nie tylko techniczna.

CZEGO DZIŚ BRAKUJE W WIELU BADANIACH?

Sześć powtarzających się problemów metodologicznych

1

Małe próby

Niska moc statystyczna,
zawyżone efekty

2

Słaba replikowalność

Wyniki trudne
do powtórzenia

3

Brak prerejestracji

Hipotezy formułowane
post hoc

4

Niejawne decyzje

Researcher degrees
of freedom

5

Niska jakość danych

Brak kontroli uwagi,
zakłócenia środowisk.


6

Zamknięty pipeline


Brak dostępu do danych,
kodu i materiałów

CZEGO DZIŚ BRAKUJE W WIELU BADANIACH?

Sześć powtarzających się problemów metodologicznych



NOWY PARADYGMAT: LABORATORIUM HYBRYDOWE



Wybór trybu ma wynikać z pytania badawczego, a nie z dostępności sprzętu

MINIMALNY CYFROWY WORKFLOW BADACZA

1 Hipoteza i pytanie badawcze

2 Prerejestracja (OSF / AsPredicted)

3 Protokół eksperymentu

4 Realizacja i zbieranie danych

5 **Dane surowe:** wersjonowanie, backup

6 **Analiza:** autom. skrypty, a nie klikanie


7 **Repozytorium:** dane, kod, materiały

8 **Publikacja** z dostępem do pipeline'u

Dobry workflow ogranicza błędy i zwiększa replikowalność badania.

PROJEKTOWANIE PYTAŃ BADAWCZYCH Z POMOCĄ AI

Modele językowe jako narzędzie konceptualne, nie wyrocznia



AI jako rozmówca krytyczny, a nie jako autorytet merytoryczny

JAK POPRAWNIE FORMUŁOWAĆ PROMPTY DLA AI I LLM-ÓW

Precyzyjne polecenie redukuje niejednoznaczność, halucynacje i koszt weryfikacji odpowiedzi

Kontekst i rola

Określ rolę modelu, odbiorcę, cel zadania oraz poziom specjalistyczności

Konkretność

Podaj zakres, ograniczenia, definicje, liczbę przykładów i oczekiwaną głębokość analizy.

Format odpowiedzi

Wymuś strukturę: tabela, lista, sekcje, limit długości lub schemat pól

Jawne kryteria

Zamiast ogólnej prośby podaj kryteria oceny, priorytety i sposób weryfikacji

Przykłady few-shot

Pokaż wzór wejścia i wyjścia, gdy potrzebny jest nietypowy lub sztywny format.

Iteracja i kontrola

Traktuj wynik jako szkic: poprawiaj prompt, sprawdzaj fakty i wymagaj źródeł pierwotnych

Słaby prompt

„Napisz coś o lęku społecznym w psychologii.”

Lepszy prompt

„Jesteś asystentem badawczym. Wymień 5 operacjonalizacji lęku społecznego z badań 2020–2025. Dla każdej: miara, typ danych, ograniczenie. Format: lista.”

Prompt powinien określać rolę, dane wejściowe, kryteria jakości, format wyjścia i sposób kontroli faktów

AI NIE ZASTĘPUJE TEORII

CO AI MOŻE WSPIERAĆ

- Przegląd terminologii i pojęć
- Generowanie hipotez alter.
- Strukturyzacja tekstu i argumentacji
- Szybkie podsumowania literatury
- Tworzenie roboczych konspektów

CZEGO AI NIE ZASTĄPI

- Trafność konstruktywa
- Wiedza metodologiczna badacza
- Weryfikacja empiryczna twierdzeń
- Odpowiedzialność naukowa
- **Weryfikacja cytowań (!)**

Halucynacje cytowań: modele generują nieistniejące artykuły z pełną precyzją. Weryfikuj każde źródło.

PRZEGLĄD LITERATURY: NARZĘDZIA PRAKTYCZNE

1. Eksploracja

Szerokie wyszukiwanie

● Semantic Scholar

Semantyczne wyszukiwanie,
cytowania, impact factor.

● Connected Papers

Graf podobieństwa
między artykułami (wizualny)

2. Mapowanie

Struktura pola badawczego

● Elicit

Ekstrakcja twierdzeń
z artykułów, porównanie badań

● Litmaps

Mapa czasowa
rozwoju pola badawczego

3. Zarządzanie

Biblioteka + cytowania

● ResearchRabbit


Sieć cytowań, artykuły
powiązane tematycznie

● Zotero

Zarządzanie bibliografią,
adnotacje, współpraca

Celem nie jest „szybciej cytować”, ale rozumieć strukturę pola badawczego

PREREJESTRACJA I TRANSPARENTNOŚĆ




Preregistracja zawiera: hipotezy · plan analizy · kryteria wykluczenia · zmienne zależne i eksploracyjne · wielkość próby

DOBÓR PRÓBY I ANALIZA MOCY STATYSTYCZNEJ


Liczebność próby jako decyzja metodologiczna, nie logistyczna

Cztery powiązane składowe



Test jednostronny vs dwustronny zmienia wymaganą liczebność próby

Mniejszy efekt → większa wymagana próba



Narzędzia

G*Power · pwr (R) · statsmodels.stats.power (Python)

Korekta na drop-out i wykluczenia:
+15–20% rezerwy do planowanej liczebności

Liczebność próby nie powinna wynikać z dostępności uczestników, lecz z oczekiwanej wielkości efektu i planu analizy

PROJEKT EKSPERYMENTU: OD PAPIERU DO PROTOKOŁU

Elementy protokołu eksperymentalnego

01

Warunki eksperymentalne

Czym manipulujemy i ile grup. Definicja warunku kontrolnego i eksperymentalnego.

02

Randomizacja

Losowe przypisanie uczestników do warunków. Losowanie kolejności bodźców.

03

Kontrola kolejności

Counterbalancing, Latin square: neutralizacja efektów uczenia i zmęczenia.

04

Manipulacja i check

Check manipulacyjny: potwierdzenie, że interwencja wywołała zamierzony efekt.

05

Zmienne zakłócające

Identyfikacja i sposoby kontroli: randomizacja, pomiaru powtarzane, kowariaty.

06

Kryteria wykluczenia

Ustalane przed badaniem: czas reakcji, błędy, kompletność danych, zgodność z protokołem.

Dobry protokół pozwala innej osobie przeprowadzić dokładnie ten sam eksperyment bez kontaktu z autorem

REKRUTACJA UCZESTNIKÓW I KONTROLA STRUKTURY PRÓBY

Skąd biorą się uczestnicy i jakie ograniczenia wprowadza kanał rekrutacji

Populacja docelowa

Kanał rekrutacji

← *bias samoselekcji*

Screening / kryteria

← *compensation bias*

Próba badawcza

Źródła rekrutacji

- Studenci
- Prolific / MTurk
- Populacja kliniczna
- Media społecznościowe

Na co zwrócić uwagę

- Kryteria włączenia/wyłączenia
- Reprezentatywność i balans grup

Źródło rekrutacji jest elementem metody badawczej
i musi być opisane równie precyzyjnie jak używana aparatura

PSYCHOPY JAKO NARZĘDZIE EKSPERYMENTALNE

Precyzja pomiaru behawioralnego - Python

TRYB BUILDER

- Interfejs graficzny, bez programowania
- Gotowe komponenty: tekst, obraz, dźwięk, klawiatura
- Wizualne budowanie prób i pętli
- Dostępny dla początkujących badaczy
- Eksport do Pythona w każdej chwili

TRYB CODER (Python)

- Pełna kontrola przez kod Python
- Adaptacyjne procedury, dynamiczne bodźce
- Integracja z EEG, eye-trackerem, EDA
- Precyzja pomiaru czasu reakcji < 1 ms
- Dowolna logika eksperymentalna

Pavlov

Platforma pozwalająca uruchamiać eksperymenty PsychoPy w przeglądarce.
Ten sam kod działa więc i online i w laboratorium. Działa na modelu licencji: opłata za sesję


JSPSYCH I EKSPERYMENTY ONLINE

Badania behawioralne w przeglądarce - JavaScript

Biblioteka jsPsych

- Eksperymenty uruchamiane w przeglądarce
- Gotowe pluginy: Stroop, IAT, n-back, flanker i inne
- Dane zapisywane lokalnie lub na serwerze (JATOS)
- Elastyczna personalizacja przez JavaScript
- Open source, aktywnie utrzymywany
- Integracja z Prolific, MTurk, SONA

Przepływ danych



Nie każdy paradygmat wymaga Javy lub własnego serwera. jsPsych działa z hostingiem statycznym

GORILLA, PAVLOVIA, LAB.JS, QUALTRICS

Kiedy używać gotowej platformy, a kiedy pisać własny eksperyment?

Narzędzie	Poziom tech.	Koszt	Elastyczność	Najlepsze zastosowanie
Gorilla	Brak kodu	Licencja instytucjonalna	Niska-średnia	Szybki deployment, badania dydaktyczne, duże projekty z budżetem
Pavlovía	PsychoPy (Python/Builder)	Opłata za sesję	Średnio-wysoka	Gdy eksperyment został zbudowany w PsychoPy i wymaga hostingu online
Lab.js	Niski (GUI + JS)	Bezpłatny (open source)	Wysoka	Alternatywa open-source z graficznym builderem i eksportem do jsPsych
Qualtrics	Brak kodu	Licencja instytucjonalna	Niska	Kwestionariusze i proste procedury; RT < 20 ms - niezalecany
jsPsych / HTML+JS	Wysoki (JavaScript)	Bezpłatny (open source)	Pełna	Niestandardowe paradygmaty, pełna kontrola nad timingiem i logiką

POMIAR CZASU REAKCJI JAKO PROBLEM TECHNICZNY

Skąd bierze się opóźnienie i jak je kontrolować?

Klawiatura / mysz

Polling rate: 125–1000 Hz → latencja 1–8 ms

System operacyjny

Scheduling przerwań, wielowątkowość → 1–10 ms

Przeglądarka

Timer JS, brak synchronizacji z vsyncem → 2–20 ms

Karta graficzna / ekran

Buforowanie klatek, jitter odświeżania → 0–16,7 ms

Pomiar łączny

Jitter online typowo: 10–50+ ms

Laboratorium

< 1 ms dokładności

PsychoPy + sprzęt specjalistyczny

Niezbędny dla RT < 50 ms

Online (przeglądarka)

10–50+ ms jitter typowo

jsPsych / PsychoPy+Pavlovía

Niedopuszczalny dla RT < 20 ms

Wniosek

Paradygmaty wymagające precyzji < 20 ms
nie nadają się do badań online.

TRAFNOŚĆ I RZETELNOŚĆ POMIARU CYFROWEGO

Wysoka rozdzielczość danych $\neq$ trafny pomiar konstruktu

Precyzja techniczna vs trafność



Pięć kluczowych pojęć

Trafność konstruktowa

Czy miara mierzy zamierzony konstrukt psychologiczny?

Trafność kryterialna

Czy wynik koreluje z zewnętrznym kryterium?

Trafność ekologiczna

Czy pomiar ma sens w warunkach naturalnych?

Rzetelność test-retest

Czy miara daje podobny wynik przy powtórzeniu?

Zgodność między urządzeniami

Czy dwa urządzenia dają porównywalne wyniki?

Nowoczesna aparatura zwiększa rozdzielczość pomiaru, ale nie zastępuje walidacji psychometrycznej

BADANIA MOBILNE I ECOLOGICAL MOMENTARY ASSESSMENT

Pomiar doświadczenia w środowisku naturalnym

EMA (Ecological Momentary Assessment)

Wielokrotny pomiar nastrojów, stanów i zachowań w czasie rzeczywistym, w codziennym środowisku uczestnika - kilka/kilkanaście razy dziennie przez dni lub tygodnie.



WEARABLES W PSYCHOLOGII

Co mierzymy i czego nie należy nadinterpretować?



EDA

Elektrodermalna aktywność

Co mierzy

Aktywacja układu współczulnego
Pobudzenie autonomiczne

Urządzenia

Empatica E4, Shimmer3, Biopac

Mierzy pobudzenie, ale nie rozpoznaje konkretnych emocji. Stres, radość i wysiłek dają podobny sygnał.



HRV

Zmienność rytmu serca

Co mierzy

Stan autonomiczny
Regulacja emocjonalna, stres

Urządzenia

Polar H10, Garmin, Apple Watch

Wymaga ekstrakcji i walidacji. Krótkie okna czasowe ograniczają interpretację.



ACT

Akcelerometria / aktygrafia

Co mierzy

Aktywność fizyczna, rytm dobowy
Jakość i długość snu

Urządzenia

ActiGraph, Fitbit, Apple Watch

Dane z urządzeń komercyjnych mają gorszą jakość, niż sprzęt badawczy. Wymaga walidacji.

Przed włączeniem wearable do protokołu: czy ta miara jest walidowana dla naszego konstruktu w podobnej populacji?

EYE-TRACKING W PRAKTYCE

Uwaga, emocje i obciążenie poznawcze

Fiksacje

Zatrzymanie wzroku ≥ 100 –150 ms. Wskaźnik aktywnego przetwarzania. Długość i liczba fiksacji różnicuje poziomy trudności.

Sakkady

Szybkie ruchy między fiksacjami. Długość i czas trwania odzwierciedlają strategię eksploracji wzrokowej.

AOI

Areas of Interest: regiony definiowane przez badacza na materiale bodźcowym. Porównanie czasu w AOI między warunkami.

Pupilo- metria

Średnica reaguje na obciążenie poznawcze i pobudzenie emocjonalne. Niezależna od kontroli wolicjonalnej.



Zastosowania:

Uwaga
selektywna

Emocje

Obciążenie
poznawcze

Diagnoza
psychologiczna

Interfejsy
i UI/UX

Czytanie
i język

Kalibracja, oświetlenie i stabilność głowy bezpośrednio wpływają na jakość danych

ANALIZA MIMIKI I EKSPRESJI EMOCJI

FACS, action units i ograniczenia automatycznej analizy twarzy

FACS: Facial Action Coding System

System anatomicznego opisu ruchów twarzy przez elementarne jednostki mięśniowe (Action Units). Opracowany przez Ekmana i Friesena. Podejście obiektywne: nie mówimy „uczestnik wygląda na szczęśliwego”, mówimy „zarejestrowano AU6 i AU12”.

Przykładowe Action Units

AU1	Uniesienie wewnętrznej części brwi	<i>smutek, strach</i>
AU4	Zyg brwi (frowning)	<i>skupienie, gniew</i>
AU6+12	Podniesienie policzka + kąt ust	<i>uśmiech Duchenne'a</i>
AU17	Uniesienie brody	<i>dezaprobatą, smutek</i>

Automatyczna analiza

Obraz / wideo / kamera

Detekcja twarzy (DNN)

Landmarki (68–478 punktów)

Klasyfikacja AU

Narzędzia: OpenFace, Py-Feat, iMotions

Kluczowe ograniczenia

- Twarz wyraża ruchy mięśni, nie emocje bezpośrednio
- Ten sam wzorzec AU pojawia się w różnych kontekstach
- Klasyfikatory 6 emocji upraszczają złożoność ekspresji
- Ograniczenia kulturowe: ekspresja nie jest uniwersalna

GŁOS I MOWA JAKO DANE PSYCHOLOGICZNE

Od prozodii do automatycznej transkrypcji

Cechy prozodyczne

- Ton podstawowy (F0) - wysokość dźwięku
- Energia i głośność wypowiedzi
- Tempo mowy (sylaby/s)
- Pauzy i ich długość

Cechy spektralne

- MFCC - standard w uczeniu maszynowym
- Formanty (F1, F2) - jakość samogłosek
- Jitter i shimmer - stabilność głosu
- Spektrogram i mel-spektrogram

Transkrypcja i NLP

- Whisper (OpenAI): wielojęzyczny, offline
- AWS Transcribe, Google Speech-to-Text
- Analiza treści, sentymentu, spójności
- Embeddingi semantyczne wypowiedzi

Przykład sygnału jako schematyczny widok falowy

niebieski - akcent zielony - zmiana tonu



Zastosowania:

Emocje i nastrój

Stres i zmęczenie

Depresja / afazja

Interakcja H-AI

Diagn. psychol.

Ograniczenie: *płeć, wiek, akcent i zmęczenie wpływają na cechy akustyczne - wymagana normalizacja wewnątrz-osobnicza*

EEG I NEUROINFORMATYKA DLA PSYCHOLOGÓW

ERP, pasma częstotliwości i preprocessing sygnału

Komponenty ERP (wybrane)

P300

Odpowiedź ok. 300 ms po bodźcu rzadkim. Wskaźnik aktualizacji kontekstu, pamięci roboczej i uwagi.

N170

Komponent czuły na twarze, ok. 170 ms po prezentacji. Wykorzystywany w badaniach percepcji społecznej.

N400

Reakcja na niespójność semantyczną w języku. Klasyczny wskaźnik w psycholingwistyce.

Pasma częstotliwości EEG

-  **Delta** *sen głęboki*
-  **Theta** *pamięć, hipokamp*
-  **Alpha** *hamowanie, odpoczynek*
-  **Beta** *aktywne przetwarzanie*
-  **Gamma** *integracja informacji*

Preprocessing sygnału

Filtrowanie

Referencja

ICA

Epokowanie

Odrzucenie epok

Narzędzia: MNE-Python, EEGLAB, BrainVision Analyzer

VR/AR W EKSPERYMENTACH PSYCHOLOGICZNYCH

Kontrola środowiska przy zachowaniu wysokiej trafności ekologicznej

Zastosowania

- Lęk wysokości
- Fobia społeczna
- PTSD i ekspozycja
- Uwaga i interakcja społeczna

Co rejestrujemy

- Ruch głowy
- Spojrzenie (eye-tracking VR)
- Pozycja ciała
- Reakcje behawioralne i fizjologiczne

Kontrola eksperymentalna

Wysoka trafność ekologiczna

VR

punkt optymalny: kontrola + immersja

Platformy

Unity + SteamVR, Unreal Engine, OpenXR,
LabStreamingLayer

Ograniczenia

Motion sickness, koszt sprzętu, standaryzacja bodźców
między sesjami

ROBOTY SPOŁECZNE I INTERAKCJA CZŁOWIEK-AI

Robot jako kontrolowany bodziec społeczny

Zmienne manipulowalne

- **Wygląd** (efekt niesamowitej doliny)
- **Ton** głosu
- **Ekspresja** mimiczna
- **Zachowanie** i reakcje
- **Dystans** interpersonalny

Platformy badawcze

- | | |
|-------------------|--|
| NAO | <i>humanoidalny, badania społeczne</i> |
| Pepper | <i>interakcja w przestrzeniach publicznych</i> |
| Furhat | <i>głowa robotyczna, dialog</i> |
| iCub | <i>platforma badawcza open-source</i> |
| Unitree G1 | <i>lokomocja, badania motoryczne</i> |

Zastosowania badawcze:

Efekt niesamowitej
doliny

Empatia wobec
robotów

Terapia ASD

Decyzje i krytyka

Co rejestrujemy

Mimika uczestnika · EDA · eye-tracking ·
mowa · czas reakcji

Wyzwanie techniczne

Precyzyjne, replikowalne zachowania robota wymagają
znajomości ROS2, SDK producenta lub systemów dialogowych

DANE MULTIMODALNE

Integracja sygnałów: synchronizacja i wspólna oś czasu

EEG

512 Hz

Eye-tracker

120 Hz

EDA

32 Hz

Kamera

30 fps

Mikrofon

44.1 kHz

LSL

LabStreamingLayer (LSL) to otwarty protokół synchronizujący strumienie danych z różnych urządzeń z dokładnością do milisekund poprzez wspólny znacznik czasu.

Resampling

Fuzja ramek danych

PCA / ICA

Modelowanie wielokanałowe

ARCHITEKTURA CYFROWEGO EKSPERYMENTU

Warstwy systemu badawczego: od bodźca do archiwum

01 Bodźce Generowanie i prezentacja materiałów eksperymentalnych

02 Akwizycja Sprzęt pomiarowy, sterowniki, SDK

03 Synchronizacja LSL, trigger TTL, znaczniki zdarzeń

04 Logowanie Automatyczny zapis metadanych, ID uczestnika, wersji protokołu

05 Przechowywanie Dane surowe → backup → wersjonowanie

06 Analiza i raportowanie Skrypty, notebooki, automatyczne raporty

KONTROLA JAKOŚCI DANYCH W TRAKCIE EKSPERYMENTU

Kontrola jakości jako część systemu akwizycji, nie etap po badaniu

Attention checks

38 / 40

zaliczonych

Jakość sygnału EEG

94%

elektrody aktywne

Brakujące dane

2%

w bieżącej sesji

Outliery wykryte

3

do przeglądu

 **Alerty w czasie rzeczywistym:** badacz prowadzący sesję widzi te wskaźniki na bieżąco i może przerwać, ponownie skalibrować lub wykluczyć uczestnika.

Dodatkowe mechanizmy kontroli jakości

- Catch trials: próby z oczywistą poprawną odpowiedzią
- Minimalny czas odpowiedzi jako filtr przeciw klikaniu na ślepo
- Kalibracja eye-trackera monitorowana w czasie sesji
- Logi błędów i autom. det. outlierów podczas zbierania danych

Kontrola jakości nie powinna zaczynać się po zakończeniu badania; musi być częścią systemu akwizycji

STANDARDY DANYCH I PORZĄDEK W REPOZYTORIUM

Struktura projektu badawczego: porządek jako metodologia

project/

├ data/

| ├── raw/

tylko do odczytu

| └ processed/

├ scripts/

├ notebooks/

├ stimuli/

├ docs/

├ results/

├ environment.yml

└ README.md

Fundamentalna zasada

Dane surowe są tylko do odczytu i nigdy ich nie nadpisujemy. Wszelkie przekształcenia wykonujemy wyłącznie przez skrypty zapisujące wynik do folderu processed.

Standard BIDS

Brain Imaging Data Structure to formalny standard opisu danych neuro/behawioralnych, coraz szerzej wymagany przez repozytoria takie jak OpenNeuro.

***Filozofia BIDS:** każdy plik danych ma parę - plik JSON z metadanymi.*

ANONIMIZACJA I PSEUDONIMIZACJA


Ochrona danych uczestników: minimalizacja i separacja

Pseudonimizacja

Identyfikator uczestnika zamiast danych osobowych w plikach danych. Odwracalna przy dostępie do klucza.

Anonimizacja

Nieodwracalne usunięcie możliwości identyfikacji uczestnika; wyższy poziom ochrony danych.



Kluczowe zasady

- Klucz łączący ID z tożsamością przechowywany oddzielnie, z ograniczonym dostępem
- Nagrania audio/wideo są danymi biometrycznymi i wymagają szczególnej zgody
- Dane wrażliwe (RODO art. 9): zdrowie psychiczne, biometria mają wyższe wymogi ochrony
- Minimalizacja: zbieramy tylko dane niezbędne do odpowiedzi na pytanie badawcze

AI W PRZYGOTOWANIU MATERIAŁÓW BADAWCZYCH

Generatywna AI jako narzędzie do tworzenia bodźców



Tekst

Scenariusze, winiety, opisy sytuacji społecznych

Obraz

Neutralne twarze, środowiska, obiekty (Stable Diffusion, DALL·E)

Głos

Bodźce werbalne ze standaryzowaną prozodią (TTS, ElevenLabs)

Ryzyko biasu

Modele generatywne mogą odtwarzać stereotypy rasowe, płciowe i kulturowe obecne w danych treningowych

Wymagana dokumentacja

Metoda generowania bodźców musi być opisana w sekcji metod artykułu, wraz z wynikami walidacji


AI W KODOWANIU DANYCH JAKOŚCIOWYCH

Automatyczna analiza treści: możliwości i wymogi intersubiektywności

Transkrypcja godziny nagrania:

Kiedyś
to 4/6 godzin pracy

Dziś
to kilka minut (Whisper)



Wymagany audyt i dokumentacja

- Zgodność kodowania AI z ludzkim koderem: współczynnik kappa Cohena lub ICC
- Dokumentacja: jaki model, jakie prompty, jaki próg pewności przy kategoryzacji
- Badacz odpowiada za interpretację i ostateczny kodebook - AI tylko przyspiesza proces

MODELE JĘZYKOWE W ANALIZIE WYPOWIEDZI

Embeddingi, klasyfikacja semantyczna i analiza podobieństwa tekstu

Techniki

Embeddingi

Reprezentacje wektorowe tekstu zachowujące znaczenie semantyczne (podobieństwo cosinusowe)

Klasyfikacja zero/few-shot

Przyporządkowanie wypowiedzi do kategorii bez wytrenowania modelu na danych oznaczonych


Wykrywanie tematów

BERTopic (embeddingi + HDBSCAN), LDA: automat. grupowanie znaczeniowe dużych zbiorów tekstu

Analiza sentymentu

Gotowe pipeline'y: VADER, cardiffnlp/twitter-roberta: ocena walencji wypowiedzi.

Redukcja wymiarowości (PCA / UMAP)



Klasyfikacja tematów

Wypowiedź	Temat (AI)	Weryf.
„Czuję się wyczerpany pracą...”	Wyczerpanie	✓
„Nie mogę spać od tygodni...”	Sen	✓
„Stresuję się przed egzaminem...”	Lęk	X → Stres

BRAKI DANYCH, OUTLIERY I DECYZJE PREPROCESSINGOWE

Preprocessing jest częścią analizy, a nie neutralną czynnością techniczną

MCAR

Braki całkowicie losowe:
bezpiecznie ignorować lub
imputować


MAR

Brak zależy od innych
obserwowanych zmiennych


MNAR

Brak zależy od samej
nieobserwowanej wartości:
najtrudniejszy przypadek.

Przed winsoryzacją



Po winsoryzacji



● Imputacja vs listwise
deletion

● Standaryzacja
zmiennych

● Kryteria usuwania -
prerejestrowane

● Analiza wrażliwości

Kryteria usuwania obserwacji ustalamy przed analizą, najlepiej w prerejestracji, nie po zobaczeniu wyników

KLASYCZNE STATYSTYKI NADAL SĄ POTRZEBNE

Fundament analizy: czego ML nie zastąpi

ANOVA i jej warianty

Testy różnic między warunkami, efekty główne i interakcje.

Regresja liniowa/logist.

Modelowanie predyktorów zmiennych wynikowych.

Modele mieszane (LMM)

Dane hierarchiczne, pomiary powtarzane, EMA.

Korekcje wielokrotności

Bonferroni, FDR (Benjamini-Hochberg) - kontrola α .

Wielkość efektu

Cohen's d, η^2 , ω^2 , r, a nie tylko $p < 0,05$.

Przedziały ufności

Zamiast lub obok wartości p.

Wartość p mówi o prawdopodobieństwie przy H_0 , a nie o wielkości efektu. Raportujmy oba.

JASP, JAMОВI, R I PYTHON

Wybór narzędzia analitycznego: kryteria i porównanie

Narzędzie	Krzywa uczenia	Bayesian	Elastyczność	Ekosystem ML
JASP	Niska (GUI)	Tak (natywnie)	Niska	Brak
jamovi	Niska (GUI nad R)	Częściowo	Średnia	Ograniczony
R	Średnia/wysoka	Tak (brms, stan)	Wysoka	Dobry (caret, tidymodels)
Python	Średnia/wysoka	Tak (PyMC)	Pełna	Bardzo dobry (sklearn, torch)

Skrypt analizy to część danych badania! Analiza bez zapisanych kroków jest niereplikowalna.

BŁĘDY WYNIKAJĄCE Z OGRANICZEŃ NUMERYCZNYCH

Dlaczego obliczenia komputerowe nie są idealnie dokładne?

1 Reprezentacja liczb

$$101101_2 = 45_{10}$$

$0,1 + 0,2 \neq 0,3$
w reprezentacji
maszynowej

2 Błędy zaokrągleń

$$0.125$$

- Każda operacja może wprowadzać mały błąd.
- Wielokrotne obliczenia zwiększają odchylenie wyniku.

3 Kumulacja błędów



W analizach wieloetapowych małe błędy sumują się.



precyzja

overflow / underflow

kumulacja błędów

niestabilność

4 Niestabilność numeryczna



Mała zmiana danych może silnie zmienić wynik algorytmu.

- odwracanie macierzy
- optymalizacja
- bardzo małe prawdopodobieństwa

5 Kolejność operacji

$$\begin{array}{ccc} (a + b) + c & \text{vs.} & a + (b + c) \\ \downarrow & & \downarrow \\ = 1.0000001 & & = 0.9999999 \end{array}$$

W arytmetyce float kolejność ma znaczenie.

6 Konsekwencje w badaniach



Różne biblioteki, CPU/GPU, typy danych i seedy mogą dawać minimalnie różne wyniki.

$p = 0,049$ vs. $p = 0,051$



Dobra praktyka



wersje bibliotek



typy danych



seed losowości



tolerancje numeryczne



walidacja wyników

Wynik nie jest faktem, ale rezultatem danych, modelu, algorytmu i ograniczonej precyzji kwantyzacji

BAYESIAN WORKFLOW DLA PSYCHOLOGII

Kiedy i jak stosować podejście bayesowskie?


Kiedy warto

- Małe próby - szerokie CI w podejściu klasycznym
- Modele hierarchiczne, wiele poziomów grupowania
- Potrzeba kwantyfikacji niepewności
- Aktualizacja wiedzy w miarę napływu danych

Pakiety

brms (R)	interfejs do Stan, składnia jak lme4
PyMC	modelowanie bayesowskie w Pythonie
JASP	GUI, bez programowania

Aktualizacja bayesowska



$$BF_{10} = 7,3$$

Dane 7×bardziej prawdopodobne przy H_1 niż przy H_0

Przepływ informacji/pracy

Weryfikacja predykcji a priori → dopasowanie modelu → weryfikacja predykcji a posteriori

MACHINE LEARNING BEZ MITOLOGII

Uczenie maszynowe w psychologii: kiedy i jak stosować

Klasyfikacja

Przewidywanie kategorii
(np. grupa kliniczna/ kontrolna)

Regresja

Przewidywanie wartości
ciągłej (np. poziom stresu)

Klasteryzacja

Wykrywanie ukrytej struktury
w danych bez etykiet

ML jest narzędziem predykcji,
a nie wyjaśniania przyczynowego.

Pipeline i pułapki

Dane

Podział (train/val/test) - ⚠ ryzyko przecieku

Preprocessing

Model

Ocena (CV, AUC)

Niezbalansowane klasy

Model przewidujący zawsze klasę większościową
(95% / 5%) ma 95% accuracy, ale jest bezużyteczny.

Stosuj F1 lub AUC-ROC zamiast samej accuracy.

DEEP LEARNING W PSYCHOLOGII

Kiedy jest sens, a kiedy nie

Dziedziny dominacji uczenia głębokiego

- **Obraz:** twarze, gesty
- **Mowa:** ASR, emocje głosowe
- **Tekst:** NLP, klasyfikacja

Mała próba



Klasyczne
ML



Fine-tuning
pretrenowanego
modelu



Trening
od zera

Duża próba

Modele wstępnie wytrenowane

wav2vec2

mowa

CLIP

obraz + tekst

BERT/RoBERTa

tekst

MediaPipe

pozycja ciała, twarz

Ograniczenia interpretowalności

Dla małych prób model głęboki jest ryzykiem overfittingu; klasyczny SVM lub model bayesowski może generalizować lepiej. Gdy musimy wyjaśnić, dlaczego model przypisał uczestnikowi dane ryzyko, czarna skrzynka jest problematyczna.

EXPLAINABLE AI I INTERPRETOWALNOŚĆ

Dlaczego model podjął taką decyzję?

SHAP

Wkład każdej cechy w predykcję modelu, bazujący na teorii gier.

LIME

Lokalne przybliżenie modelu liniowego wokół jednej predykcji.


Attention maps

Wizualizacja, na czym skupia się model transformerowy.

Analiza błędów

Dla których podgrup model myli się najczęściej?
To może ujawnić bias systemowy.

Co model widzi u tego uczestnika? (SHAP)



INTERPRETACJA WYNIKÓW I GRANICE WNIOSKOWANIA

Co można, a czego nie można powiedzieć na podstawie wyników

Od wyniku do uzasadnionego wniosku

Wynik badania

Tylko ta populacja


Korelacja, nie
przyczynowość

Uzasadniony
wniosek

O czym łatwo zapomnieć

- Efekt statystycznie istotny $\neq$ praktycznie znaczący
- Niepewność modelu to część wyniku, nie dodatek
- Model AI mówi „co”, rzadko „dlaczego”
- Generalizacja ograniczona do zbadanej populacji


Niepewność jest częścią wyniku



Publikowalny wynik to nie tylko istotność statystyczna, ale poprawnie ograniczony zakres wnioskowania

GRANICE LUDZKIEGO POZNANIA


Co można, a czego nie można powiedzieć na podstawie wyników?



**Doświadczenie subiektywne nie jest kopią rzeczywistości,
lecz predykcijną konstrukcją mózgu korygowaną przez dane zmysłowe**

EPISTEMOLOGICZNE GRANICE INTERPRETACJI WYNIKÓW

Od predykcji i korelacji do ostrożnego wnioskowania naukowego



Granice interpretacji określają naukową wiarygodność wniosku

REPLIKOWALNOŚĆ OBLICZENIOWA

Seed, wersje, kontenery

1

Ziarno losowości (seed)

`np.random.seed(42)` - warunek konieczny

2

Wersjonowanie bibliotek

`pip freeze`, `conda export`, `renv (R)`

3

Git

Historia zmian kodu, tagowanie wersji przy submisji (publikacji)

4

Kontenery (Docker)

Zamrożone środowisko obliczeniowe; pełna izolacja

DVC

(version control system)

wersjonowanie
danych i kodu

Dla większości projektów wystarczą określony seed i plik z wersjami bibliotek;
Dockera stosujemy dopiero w większych, długoterminowych projektach.

PUBLIKOWANIE DANYCH I KODU

Otwarty pakiet replikacyjny: co, gdzie i jak udostępnić

**Dane + skrypty
+ materiały**



**Zenodo
/ OSF**



DOI



**Artykuł
(link)**

Zenodo

Bezpłatne archiwum z DOI, integracja z GitHub. Prowadzone przez CERN.

OSF

Zarządzanie projektem, prerejestracja, udostępnianie danych i materiałów.

GitHub / GitLab

Kod, historia wersji, README z instrukcją replikacji.

Licencje

Dane: CC BY 4.0 **Kod:** MIT / Apache 2.0

README

Bez dokumentacji nawet dostępne dane są bezużyteczne dla zewnętrznego badacza.

ETYKA, RODO I ODPOWIEDZIALNOŚĆ BADACZA

Odpowiedzialność etyczna w cyfrowym badaniu empirycznym

Zgoda

Opis procedury,
zakresu danych,
ryzyka, możliwości
wycofania.

Dane wrażliwe

RODO art. 9 -
zdrowie psychiczne,
biometria,
orientacja

Monitoring

Wyrażna zgoda na
zbieranie danych
w tle (lokalizacja,
aktywność).

Bias

Modele AI mogą
dyskryminować
grupy
niedoreprezen-
towane w danych

Granice AI

Decyzje kliniczne
nie mogą opierać
się wyłącznie na
modelu

Komisja etyczna ocenia protokoły przed badaniem i to jest mechanizm ochrony uczestnika i badacza, a nie biurokratyczna przeszkoda.

PRAKTYCZNA LISTA STARTOWA

10 rzeczy do wdrożenia (najlepiej już od jutra)

1

Przarejestruj hipotezy i plan analizy na OSF przed zebraniem danych

2

Ustrukturyzuj projekt: data/raw, data/processed, scripts, README

3

Zainstaluj Git i commituj zmiany kodu po każdej sesji analitycznej

4

Ustaw ziarno losowości we wszystkich skryptach

5

Oblicz moc statystyczną przed badaniem (G*Power, pwr w R)

6

Przepilotuj bodźce. Walidacja przed właściwym badaniem

7

Wybierz narzędzie analizy i zapisz jego wersję

8

Udostępnij materiały na OSF lub GitHub wraz ze złożeniem (submisją) artykułu

9

Udokumentuj proces przetwarzania danych: kto co przetwarzał i kiedy

10

Skonsultuj protokół z komisją etyczną przed pierwszą sesją

Dobra nauka to suma **dobrych decyzji**: metodologicznych, technicznych i etycznych